

Projet de Fin d'Année

**Développement d'un système d'aide à la décision pour
la prédiction de la gravité des intoxications au Maroc à
partir des données du CAPM.**

Préparé par : **BASMA HOURMATALLAH
SABERA HADDOUCHAN**

Sous la direction de : **M. ASRAOUI ABDELGHANI**

Dédicace

À nos chers parents,

Qui n'ont cessé de nous encourager et de prier pour nous tout au long de notre parcours.
Aucune dédicace ne saurait exprimer notre profonde gratitude pour leurs sacrifices, leur soutien indéfectible et leur confiance en nos capacités.

À nos familles et à nos proches,

Pour leur patience, leurs encouragements constants et leur présence à chaque étape de ce travail.

À tous nos enseignants de l'INSEA,

Qui ont contribué à notre formation et à l'acquisition des compétences nécessaires à la réalisation de ce projet.

Nous dédions ce modeste travail, fruit d'un travail d'équipe mené avec rigueur, patience et complémentarité.

Remerciements

Au terme de ce projet de fin d'année, nous tenons à exprimer notre profonde reconnaissance à toutes les personnes qui, de près ou de loin, ont contribué à sa réalisation.

Nos remerciements s'adressent en premier lieu à notre encadrant M. ASRAOUI Abdelghani pour sa disponibilité, ses conseils avisés, sa rigueur scientifique et le temps précieux qu'il nous a accordé tout au long de ce travail. Ses orientations méthodologiques ont été déterminantes dans la construction et l'aboutissement de ce projet.

Nous remercions également l'ensemble du corps professoral de l'Institut National de Statistique et d'Économie Appliquée (INSEA) pour la qualité de la formation dispensée, qui nous a permis d'acquérir les bases statistiques et techniques indispensables à la réalisation de ce travail.

Nous adressons nos sincères remerciements au Centre Anti Poison et de Pharmacovigilance du Maroc (CAPM) pour la mise à disposition des données ayant rendu possible cette étude, ainsi qu'à toute personne ayant facilité l'accès à ces informations.

Que tous ceux qui ont contribué, de quelque manière que ce soit, à l'aboutissement de ce projet trouvent ici l'expression de notre sincère gratitude.

Résumé

Les intoxications constituent un enjeu majeur de santé publique au Maroc, suivi de près par le Centre Anti Poison et de Pharmacovigilance du Maroc (CAPM) à travers sa mission de toxicovigilance. C'est dans ce cadre que s'inscrit ce projet de fin d'année, réalisé au sein du CAPM, dont l'objectif est de développer un système d'aide à la décision capable de prédire la gravité clinique d'une intoxication à partir des caractéristiques du cas déclaré.

Pour parvenir à cet objectif, la première étape a consisté à exploiter la base de données du CAPM couvrant la période 2020–2025. Cette base ayant été constituée à partir de déclarations hétérogènes, un travail conséquent de nettoyage et d'harmonisation des variables s'est imposé, avec une vigilance particulière portée à la fiabilité des données et à la limitation des risques de biais susceptibles de fausser la modélisation ultérieure. L'analyse exploratoire menée sur la base ainsi consolidée a alors mis en évidence un déséquilibre marqué entre les classes de la variable cible du projet, la gradation finale de gravité de l'intoxication, ainsi que des variations notables selon les caractéristiques sociodémographiques et les circonstances des cas déclarés. Ces constats ont directement orienté les choix méthodologiques de la suite du projet.

Sur cette base, plusieurs modèles de classification, à savoir la régression logistique, le Random Forest et XGBoost, ont été construits puis comparés afin d'identifier l'approche la plus adaptée à la prédiction de la gravité. Le déséquilibre marqué de la classe des intoxications sévères, identifié en amont, a d'abord été traité par SMOTE, avant d'être corrigé par SMOTENC afin de mieux respecter la nature catégorielle des variables. Pour renforcer davantage la fiabilité statistique de cette classe critique, les grades de sévérité les plus rares ont ensuite été fusionnés. L'ensemble des modèles a été évalué à l'aide du F1-macro, du Quadratic Weighted Kappa et du rappel de la classe sévère, avec un seuil de décision optimisé via le F2-score, puis interprété grâce à la méthode SHAP afin d'en dégager les facteurs les plus déterminants.

Au terme de cette démarche, le modèle retenu, un Random Forest couplé à SMOTENC, s'est distingué par ses performances et son interprétabilité, atteignant un rappel de 46,1 % sur la classe sévère après optimisation du seuil de décision (contre 21,7 % au seuil par défaut). Il a ainsi pu être intégré dans une application interactive développée avec Streamlit, permettant une prédiction en temps réel de la gravité d'un cas d'intoxication et offrant, à terme, un véritable outil d'aide à la décision clinique pour le CAPM.

Mots-clés : Intoxication, Toxicovigilance, CAPM, Gravité clinique, Machine Learning, Classification, Déséquilibre des classes, SMOTENC, Random Forest, SHAP, Aide à la décision clinique.

Abstract

Poisoning cases represent a major public health concern in Morocco, closely monitored by the Moroccan Poison Control and Pharmacovigilance Centre (CAPM) through its toxicovigilance activities. It is within this context that the present end-of-year project was carried out at CAPM, with the aim of developing a decision-support system capable of predicting the clinical severity of a poisoning case based on its reported characteristics.

To reach this objective, the first step consisted in working with the CAPM database covering the 2020–2025 period. As this database was built from heterogeneous declarations, substantial data cleaning and harmonization work proved necessary, with particular attention paid to data reliability and to limiting sources of bias that could later distort the modeling process. Exploratory analysis of the resulting, consolidated dataset then revealed a marked imbalance across the classes of the project’s target variable, the final severity grade of the poisoning, along with notable variations according to sociodemographic characteristics and the circumstances of reported cases. These findings directly shaped the methodological choices made throughout the rest of the project.

Building on these insights, several classification models, namely logistic regression, Random Forest, and XGBoost, were developed and compared in order to identify the most suitable approach for predicting severity. The pronounced imbalance of the severe poisoning class, identified earlier, was first addressed using SMOTE, before being corrected using SMOTENC to better account for the categorical nature of the variables. To further strengthen the statistical reliability of this critical class, the rarest severity grades were subsequently merged. All models were evaluated using macro F1-score, Quadratic Weighted Kappa, and recall on the severe class, with an optimized decision threshold based on the F2-score, and were then interpreted using the SHAP method to identify the most influential predictive factors.

At the end of this process, the selected model, a Random Forest combined with SMOTENC, stood out for both its performance and its interpretability, achieving a recall of 46.1 % on the severe class after decision threshold optimization (compared to 21.7 % at the default threshold). It was accordingly integrated into an interactive Streamlit application, enabling real-time prediction of poisoning severity and offering CAPM a genuine clinical decision-support tool.

Keywords: Poisoning, Toxicovigilance, CAPM, Clinical severity, Machine Learning, Classification, Class imbalance, SMOTENC, Random Forest, SHAP, Clinical decision support.

Table des matières

Dédicace	2
Remerciements	3
Résumé	4
Abstract	5
Abréviations	9
Introduction Générale	13
1 Cadre théorique de l'étude	16
1.1 Présentation du Centre Anti Poison et de Pharmacovigilance du Maroc (CAPM)	17
1.2 Contexte de la toxicovigilance au Maroc	19
1.3 Définitions et concepts clés	20
1.3.1 Intoxication	20
1.3.2 Gravité clinique	21
1.3.3 Circonstance et sous-circonstance d'exposition	21
1.3.4 Voie d'exposition	21
1.4 Problématique et objectifs du stage	21
2 Données et méthodologie	23
2.1 Présentation des données	24
2.1.1 Source et mode de collecte des données	24
2.1.2 Description de la base de données CAPM (2020–2025)	24
2.1.3 Description des variables	25
2.1.4 Variable cible : la Gradation finale	26
2.2 Prétraitement des données	27
2.2.1 Sélection de la période d'étude et des variables	27

2.2.2	Gestion des valeurs manquantes	29
2.2.3	Encodage et traitement de la variable cible.....	32
2.2.4	Harmonisation des variables catégorielles	33
2.3	Analyse exploratoire des données	37
2.3.1	Distribution de la variable cible	37
2.3.2	Analyse univariée des variables explicatives	38
2.3.3	Relations bivariées avec la gravité	40
2.3.4	Tests statistiques d'association	44
2.4	Méthodologie adoptée	46
3	Modélisation	48
3.1	Modèles de prédiction utilisés	49
3.1.1	Régression logistique	49
3.1.2	Random Forest	49
3.1.3	XGBoost	50
3.2	Stratégies de construction des modèles	50
3.2.1	Modèles sans regroupement de la variable Produit	50
3.2.2	Modèles avec regroupement de la variable Produit (<i>Produit_Regroupe</i>)	50
3.3	Traitement du déséquilibre des classes	51
3.3.1	Principe de la technique SMOTE	51
3.3.2	Limites de SMOTE appliqué après encodage One-Hot	52
3.3.3	Correction méthodologique : SMOTENC pour variables catégorielles	52
3.3.4	Intégration dans un pipeline de validation croisée	53
3.4	Fusion des grades de sévérité	54
3.5	Optimisation des hyperparamètres	55
3.6	Métriques d'évaluation des performances	56
3.6.1	Matrice de confusion (VP, FP, VN, FN)	56
3.6.2	Précision, rappel et F1-score	57
3.6.3	F1-macro	57
3.6.4	Quadratic Weighted Kappa (QWK)	58
3.6.5	Choix du rappel (recall) comme critère clinique prioritaire.....	59
4	Résultats et interprétation	60
4.1	Résultats des modèles testés	61
4.1.1	Résultats sans regroupement de la variable Produit	61
4.1.2	Résultats avec regroupement de la variable Produit	61
4.1.3	Résultats après optimisation des hyperparamètres	62
4.2	Résultats sur le problème à 4 classes (après fusion des grades sévères)	63
4.2.1	Comparaison Random Forest vs XGBoost	63
4.2.2	Random Forest avec SMOTENC (variables catégorielles brutes)	63
4.2.3	Validation par cross-validation (stabilité des résultats)	64

4.2.4	Matrices de confusion et courbes ROC / precision-recall	64
4.2.5	Choix du seuil de décision optimal (F2-score) pour la classe Sévère ..	66
4.3	Sélection du modèle final	68
4.4	Interprétabilité du modèle (SHAP)	68
4.4.1	Méthodologie SHAP	68
4.4.2	Importance des variables pour la classe Sévère	68
4.4.3	Comparaison de l'interprétabilité entre Random Forest et XGBoost .	70
4.4.4	Discussion clinique des variables déterminantes	71
4.5	Discussion des résultats et limites	71
5	Conception du système d'aide à la décision	72
5.1	Architecture générale du système	73
5.2	Conception de l'interface (Streamlit)	74
5.2.1	Chargement des artefacts du modèle final	74
5.2.2	Ergonomie et charte visuelle	75
5.3	Fonctionnalités et intégration du modèle	77
5.4	Perspectives d'amélioration	78
	Conclusion Générale	80
	Bibliographie	83
	A Extraits de code	85
	B Dictionnaire des variables	87

Abréviations

CAPM : Centre Anti Poison et de Pharmacovigilance du Maroc

INSEA : Institut National de Statistique et d'Économie Appliquée

PFA : Projet de Fin d'Année

PSS : Poisoning Severity Score

RF : Random Forest

LR : Régression Logistique

XGBoost : Extreme Gradient Boosting

SMOTE : Synthetic Minority Over-sampling Technique

SMOTENC : Synthetic Minority Over-sampling Technique for Nominal and Continuous features

SHAP : SHapley Additive exPlanations

CV : Cross-Validation (validation croisée)

QWK : Quadratic Weighted Kappa

VP / FP / VN / FN : Vrais Positifs / Faux Positifs / Vrais Négatifs / Faux Négatifs

ROC : Receiver Operating Characteristic

AUC : Area Under the Curve — l'aire sous la courbe ROC (Receiver Operating Characteristic)

χ^2 : Test du Khi-deux (Chi-carré)

Liste des tableaux

1	Dimensions de la base de données brute	25
2	Répartition des cas selon l'année de réception	25
3	Description des variables retenues pour l'étude	26
4	Modalités de la variable cible <i>Gradation finale</i>	27
5	Répartition des cas par année sur la période retenue (2020-2025)	28
6	Dimensions de la base après sélection de la période et des variables	29
7	Taux de valeurs manquantes avant traitement	29
8	Valeurs manquantes de la variable cible avant et après traitement	30
9	Taux de valeurs manquantes après suppression des variables et des obser- vations sans cible	31
10	Taux de valeurs manquantes avant et après imputation	32
11	Distribution de la variable cible après harmonisation, avant épuration	32
12	Distribution finale de la variable cible <i>Gradation finale</i>	33
13	Réduction du nombre de modalités après harmonisation	34
14	Répartition des cas entre produits nommés et catégorie « AUTRE »	36
15	Variables retenues à l'issue du prétraitement	37
16	Modalité dominante par variable explicative catégorielle	40
17	Âge moyen des patients par grade de gravité	43
18	Test du Chi-2 — Association avec la Gradation finale	45
19	V de Cramér — Force de l'association avec la Gradation finale	45
20	Répartition des observations entre entraînement et test	46
21	Effectifs des grades sévères avant et après fusion	55
22	Espace de recherche des hyperparamètres pour le Random Forest, selon le pipeline	56
23	Espace de recherche des hyperparamètres pour XGBoost	56
24	Performances des modèles initiaux, sans regroupement de la variable Pro- duit (5 classes)	61
25	Performances des modèles avec Produit_Regroupe et fusion des grades sévéres (SMOTE classique)	62
26	Comparaison SMOTE classique et SMOTENC (Random Forest, 4 classes)	63

27	Recall, précision et F2-score selon le seuil de décision (classe Sévère, SMO-TENC)	67
28	Artefacts du modèle final chargés par l'application	73
29	Échelle de gravité et conduite à tenir associée, affichées dans l'application .	76
30	Dictionnaire des variables retenues pour la modélisation	88

Table des figures

1.1	Logo du CAPM	17
1.2	Programme OMS pour la pharmacovigilance internationale	18
1.3	Organigramme du Centre Anti Poison et de Pharmacovigilance du Maroc (CAPM)	19
2.1	Distribution des cas selon le grade de gravité	38
2.2	Distribution de l'âge des patients	39
2.3	Répartition des cas par tranche d'âge	39
2.4	Gravité des intoxications selon le sexe	40
2.5	Gravité des intoxications selon la tranche d'âge	41
2.6	Gravité des intoxications selon le milieu	41
2.7	Gravité des intoxications selon la région	42
2.8	Âge des patients en fonction du grade de sévérité	42
2.9	Répartition du grade de gravité (%) selon la circonstance	43
2.10	Répartition du grade de gravité (%) selon le type de produit	44
3.1	Répartition des modalités de la variable <i>Produit_Regroupe</i>	51
3.2	Comparaison schématique du mécanisme d'interpolation de SMOTE et de SMOTENC sur une variable catégorielle	53
3.3	Schéma du pipeline SMOTENC intégré à la validation croisée	54
4.1	Matrice de confusion du modèle Random Forest + SMOTENC	65
4.2	Matrice de confusion normalisée (pourcentage par classe réelle)	65
4.3	Courbes ROC multiclasse (one-vs-rest) : Random Forest + SMOTENC	66
4.4	Compromis précision/rappel selon le seuil de décision, classe Sévère	67
4.5	Importance des variables (SHAP) pour la prédiction de la classe Sévère	69
4.6	Impact détaillé des variables (SHAP) sur la prédiction de la classe Sévère	70
5.1	Architecture générale du système d'aide à la décision	74
5.2	Onglet d'accueil de l'application	75
5.3	Formulaire de saisie d'un cas dans l'onglet Prédiction	76
5.4	Résultat de la prédiction pour le cas saisi	77

Introduction Générale

Les intoxications figurent parmi les urgences médicales les plus fréquentes à l'échelle mondiale, touchant chaque année des millions de personnes et représentant une charge importante pour les systèmes de santé. Qu'elles soient d'origine accidentelle ou volontaire, elles se caractérisent par une grande hétérogénéité clinique : selon le produit en cause, la voie d'exposition, l'âge du patient ou les circonstances de survenue, une intoxication peut évoluer sans conséquence notable ou, à l'inverse, engager le pronostic vital. Cette variabilité rend l'évaluation rapide de la gravité d'un cas déclaré particulièrement délicate, et pourtant déterminante pour orienter la prise en charge.

Dans les pays à ressources sanitaires limitées, ce défi est amplifié par le volume important de déclarations à traiter et par la difficulté d'objectiver, de façon systématique, les facteurs qui font basculer un cas vers une forme sévère. L'évaluation de la gravité repose alors largement sur le jugement clinique du praticien, sans appui structuré sur l'historique des cas déjà recensés, alors même que cet historique, lorsqu'il est exploité, peut révéler des régularités précieuses.

Au Maroc, le Centre Anti Poison et de Pharmacovigilance du Maroc (CAPM) dispose, à travers ses missions de toxicovigilance, d'une base de données conséquente couvrant plusieurs années de déclarations de cas d'intoxication. Cette base constitue une ressource précieuse, mais dont le potentiel prédictif reste largement inexploité : les variables recueillies au moment de la déclaration (produit, voie d'exposition, circonstance, profil sociodémographique du patient) ne sont, à notre connaissance, pas encore mobilisées de façon systématique pour anticiper la gravité clinique d'un cas dès son signalement.

La littérature internationale identifie pourtant un ensemble de déterminants récurrents de la sévérité d'une intoxication : nature du toxique, voie et circonstance d'exposition, âge du patient, ou encore délai de prise en charge. Peu de travaux marocains, en revanche, ont cherché à formaliser ces déterminants à l'aide d'outils de modélisation statistique et d'apprentissage automatique appliqués aux données propres au contexte national, alors qu'une telle démarche pourrait fournir un appui concret à la décision clinique.

C'est dans cette perspective que s'inscrit ce projet de fin d'année, réalisé au sein du CAPM. Il poursuit une double ambition : d'une part, construire, à partir de la base de données du CAPM (2020-2025), un modèle capable de prédire la gravité clinique d'une intoxication à partir des caractéristiques disponibles dès la déclaration ; d'autre part, identifier les facteurs les plus déterminants de cette gravité, afin d'en dégager des enseignements cliniquement interprétables. L'objectif final est de mettre ce travail au service du CAPM à travers un outil d'aide à la décision concret et directement utilisable.

Ce rapport s'organise en cinq chapitres. Le premier pose le cadre théorique de l'étude, à travers les définitions et concepts nécessaires à la compréhension du sujet. Le deuxième

présente les données mobilisées ainsi que la méthodologie de prétraitement et d'analyse exploratoire mise en œuvre pour en garantir la fiabilité. Le troisième détaille les modèles de classification construits et les stratégies adoptées pour traiter le déséquilibre marqué des classes de gravité. Le quatrième présente et interprète les résultats obtenus, notamment à travers l'analyse SHAP des facteurs déterminants. Le cinquième, enfin, décrit la conception de l'application interactive développée pour intégrer le modèle retenu dans un outil utilisable en pratique clinique.

Cadre théorique de l'étude

Avant d'aborder la démarche méthodologique et les travaux de modélisation menés dans ce projet, il convient de poser le cadre dans lequel il s'inscrit. Ce chapitre présente d'abord la structure d'accueil, le Centre Anti Poison et de Pharmacovigilance du Maroc, ainsi que le contexte de la toxicovigilance dans lequel elle opère. Il précise ensuite les concepts et définitions nécessaires à la compréhension du sujet, avant de formuler la problématique et les objectifs du présent travail.

1.1 Présentation du Centre Anti Poison et de Pharmacovigilance du Maroc (CAPM)

Le Centre Anti Poison et de Pharmacovigilance du Maroc (CAPM) est une structure d'utilité publique relevant du ministère de la Santé. Il a été créé en 1975 au sein de l'Institut d'Hygiène, mais ce n'est qu'en 1989 qu'un véritable développement a vu le jour, par la structuration de ses activités de toxicovigilance et de pharmacovigilance. Ces activités ont ensuite été renforcées par la création d'un service d'information toxicologique fonctionnant 24h/24 en 1991, puis par la création du Laboratoire de Toxicologie et de Pharmacologie en 1994. En 2002, le CAPM a bénéficié d'une autonomie physique, par le déménagement vers de nouveaux locaux, et d'une gestion budgétaire individualisée. Le Centre a pour double mission la toxicovigilance, c'est-à-dire la surveillance et la prévention des intoxications, et la pharmacovigilance, centrée sur le suivi des effets indésirables liés aux produits de santé. Ces deux activités s'appuient sur un système national de déclaration : tout cas d'intoxication ou d'effet indésirable peut être signalé au Centre, que ce soit par un professionnel de santé, une structure hospitalière ou un particulier, ce qui permet au CAPM de constituer, depuis plusieurs décennies, une base de données couvrant l'ensemble du territoire national.



FIGURE 1.1 – Logo du CAPM

Au-delà de la collecte et du traitement des déclarations, le Centre assure un rôle d'information et de conseil auprès des citoyens, des professionnels de santé et des institutions, et contribue à l'élaboration de stratégies nationales de prévention, notamment autour des

principales causes d'intoxication recensées au Maroc. C'est dans le cadre de cette mission de toxicovigilance, et à partir des données ainsi collectées, que s'inscrit le présent projet.

Sur le plan institutionnel, le Maroc figure parmi les pays pionniers du continent africain en matière de vigilance sanitaire : il a été, avec l'Afrique du Sud, le premier pays africain à intégrer le programme international de pharmacovigilance de l'OMS en 1992. L'Organisation Mondiale de la Santé (OMS), avec l'augmentation continue du nombre de ses États membres participant à ce programme, a besoin d'un support technique pour répondre à ses objectifs auprès des États membres. Ce besoin se traduit par la création de Centres Collaborateurs.

C'est dans ce cadre que le CAPM a été nommé, en 2011, Centre Collaborateur de l'OMS (CCOMS) pour la pharmacovigilance, une nomination survenue après celle du CCOMS d'Uppsala (UMC) en Suède (1978) et celle de l'Université d'Accra au Ghana (2010), et officiellement annoncée lors de la Réunion Annuelle des Centres Nationaux de Pharmacovigilance à Dubrovnik, en Croatie. La Figure 1.2 illustre l'articulation entre le siège de l'OMS, les centres collaborateurs et les centres nationaux de pharmacovigilance au sein de ce programme.




FIGURE 1.2 – Programme OMS pour la pharmacovigilance internationale

Le CAPM a par ailleurs obtenu la certification ISO 9001 pour son système de management de la qualité, reconnaissant la fiabilité de ses processus de gestion des alertes et

des vigilances sanitaires.

Le CAPM est placé sous la direction de la Directrice du Centre, à laquelle sont rattachées une Unité Qualité et un Service Administratif, ainsi que deux unités transversales : Coopération et Recherche & Développement, et Technologies de l'Information. Les activités opérationnelles du Centre sont réparties entre trois services principaux : le service de Toxicovigilance, le Laboratoire, et le service de Pharmacovigilance. C'est le service de Toxicovigilance qui assure la collecte et le traitement des déclarations de cas d'intoxication constituant la base de données exploitée dans ce projet. La figure 1.3 présente l'organigramme du Centre.




FIGURE 1.3 – Organigramme du Centre Anti Poison et de Pharmacovigilance du Maroc (CAPM)

1.2 Contexte de la toxicovigilance au Maroc

La toxicovigilance désigne l'ensemble des activités de surveillance, d'alerte et de prévention mises en place face aux risques d'intoxication, qu'ils soient d'origine médica-

menteuse, alimentaire, chimique, environnementale ou animale. Au Maroc, cette mission repose principalement sur le CAPM, qui centralise les déclarations de cas provenant de l'ensemble du territoire national à travers un réseau de notification impliquant les structures hospitalières, les professionnels de santé et, dans une moindre mesure, les particuliers eux-mêmes.

Deux modes de déclaration coexistent : la déclaration passive, initiée spontanément par le déclarant, et la déclaration active, obtenue par des enquêtes de collecte menées directement auprès des structures de santé. Le CAPM a lui-même souligné, dans plusieurs de ses publications, que le système de déclaration passive reste marqué par une sous-notification importante, la comparaison entre les deux modes révélant un taux d'exhaustivité national très partiel.

La gouvernance du dispositif s'est structurée progressivement. En 2017, la Commission Nationale de Toxicovigilance a été instituée, réunissant le CAPM et plusieurs directions du ministère de la Santé ainsi que les directions régionales concernées, avec pour objectif de coordonner les stratégies de lutte contre les principales causes d'intoxication. C'est notamment dans ce cadre qu'a été pilotée la stratégie nationale de lutte contre les piqûres et envenimations scorpioniques, mise en place dès 1999, qui a permis de faire chuter significativement le taux de létalité associé à cette cause d'intoxication, longtemps la plus fréquente au Maroc.

Le CAPM diffuse par ailleurs ses résultats à travers sa publication trimestrielle Toxicologie Maroc et assure une mission d'assistance continue via une ligne d'urgence dédiée. C'est cette infrastructure de collecte, cumulée sur plusieurs décennies, qui constitue la base de données exploitée dans le présent projet.

1.3 Définitions et concepts clés

Avant d'aborder la méthodologie du projet, il est nécessaire de préciser un certain nombre de concepts utilisés tout au long de ce rapport, issus pour la plupart de la terminologie standardisée en toxicologie clinique.

1.3.1 Intoxication

Une intoxication désigne l'ensemble des manifestations cliniques consécutives à l'exposition d'un organisme à une substance toxique, que cette exposition soit accidentelle, volontaire ou liée à un effet indésirable. Elle peut concerner un produit unique ou plusieurs produits combinés, et sa gravité dépend à la fois de la nature du toxique, de la dose, de la voie d'exposition et des caractéristiques du patient.

1.3.2 Gravité clinique

La gravité clinique d'une intoxication désigne le degré de sévérité des manifestations cliniques provoquées par l'exposition à un agent toxique. Elle dépend de plusieurs facteurs : nature et dose du toxique, voie d'exposition, terrain du patient, et s'étend d'une absence totale de symptômes à un tableau clinique engageant le pronostic vital, voire au décès. En toxicologie clinique, cette gravité est généralement évaluée à l'aide d'échelles standardisées, qui traduisent la sévérité observée en une gradation discrète exploitable à des fins de suivi épidémiologique.

1.3.3 Circonstance et sous-circonstance d'exposition

La circonstance d'exposition qualifie le contexte dans lequel l'intoxication est survenue. On distingue classiquement trois grandes circonstances : accidentelle, volontaire (le plus souvent à visée suicidaire) et liée à un effet indésirable, lorsque l'intoxication résulte d'un usage conforme d'un produit de santé. La sous-circonstance affine cette classification en précisant la nature exacte de l'exposition (accident domestique classique, exposition alimentaire, erreur thérapeutique, exposition professionnelle, etc.), et constitue une variable centrale pour la modélisation, dans la mesure où elle est fortement corrélée à la gravité et au type de produit en cause.

1.3.4 Voie d'exposition

La voie d'exposition correspond au mode par lequel l'agent toxique a pénétré dans l'organisme. Les principales voies rencontrées dans les données du CAPM sont la voie orale (ingestion), l'inhalation, la voie cutanée (contact avec la peau) et la voie oculaire, auxquelles s'ajoutent des voies plus rares telles que la voie auriculaire, la morsure ou la piqûre (notamment pour les envenimations), ou encore l'injection.

1.4 Problématique et objectifs du stage

Face à un cas d'intoxication nouvellement déclaré, l'enjeu immédiat pour le praticien est d'évaluer aussi vite et aussi justement que possible la gravité probable de la situation, afin d'orienter la prise en charge du patient. Or, une intoxication peut évoluer de façons très différentes selon le produit en cause, la voie et les circonstances de l'exposition, ou encore le profil du patient : certains cas restent bénins et se résolvent spontanément, tandis que d'autres évoluent rapidement vers un tableau clinique sévère, voire fatal. Cette hétérogénéité rend l'anticipation de la gravité difficile, en particulier lorsque les informations disponibles au moment de la déclaration sont encore limitées.

Cette difficulté n'est pas propre à un cas isolé : elle se pose de façon récurrente, à chaque nouvelle déclaration, et pèse directement sur la capacité des structures de santé à prioriser les cas à risque. Pouvoir estimer, dès la déclaration, la gravité probable d'un cas présenterait ainsi un double intérêt : clinique, en identifiant plus tôt les situations nécessitant une prise en charge urgente ; et organisationnel, en aidant à mieux répartir les ressources face à l'ensemble des cas signalés. C'est précisément cette question qui constitue le point de départ du présent projet.

C'est dans cette perspective que s'inscrit le stage réalisé au sein du CAPM, dont l'objectif est de développer un système capable de prédire la gravité clinique d'une intoxication à partir des caractéristiques d'un cas déclaré. Ce système s'appuie sur la base de données du CAPM couvrant la période 2020-2025 et repose sur des techniques de Machine Learning, en vue d'aboutir à un outil directement exploitable par le Centre.

Données et méthodologie

Ce chapitre présente les données mobilisées pour ce projet ainsi que la démarche méthodologique suivie pour les exploiter. Il décrit d’abord la base de données du CAPM et ses principales caractéristiques, avant de détailler le travail de prétraitement mené pour en garantir la fiabilité. Il propose ensuite une analyse exploratoire des données consolidées, puis expose la méthodologie générale adoptée pour la suite du projet.

2.1 Présentation des données

2.1.1 Source et mode de collecte des données

Les données exploitées dans ce projet proviennent de la base de déclarations du CAPM, alimentée en continu depuis plusieurs décennies dans le cadre de sa mission de toxicovigilance. Chaque enregistrement correspond à un cas d’intoxication signalé au Centre, qu’il s’agisse d’une déclaration spontanée (réalisée par un professionnel de santé, une structure hospitalière ou un particulier) ou d’un cas recueilli dans le cadre d’une enquête active. Les informations associées à chaque cas : profil du patient, circonstances de l’exposition, nature du toxique en cause, symptomatologie et évolution, sont saisies au moment du signalement, généralement lors d’un échange téléphonique entre le déclarant et le Centre, puis consolidées dans une base de données centralisée. C’est cette base, extraite au format Excel, qui a été mise à disposition pour ce projet.

2.1.2 Description de la base de données CAPM (2020–2025)

Dans sa forme brute, la base transmise couvre l’ensemble des déclarations enregistrées par le CAPM et comprend 38 559 observations, chacune décrite par 98 variables. Chaque ligne correspond à un cas déclaré, identifié par un numéro d’enregistrement et un code de dossier, et documenté sur plusieurs plans : des informations administratives (date et heure de réception, type de déclarant, provenance géographique), des informations relatives au patient (âge, sexe, milieu de résidence, région), des informations sur l’exposition (date et heure d’intoxication, circonstance, produit ou substance en cause, voie d’exposition), des informations cliniques (symptomatologie, traitements administrés, durée d’hospitalisation) et, enfin, une évaluation de l’issue du cas à travers la gradation de gravité.

TABLE 1 – Dimensions de la base de données brute

Élément	Nombre
Cas (observations)	38 559
Variables	98

La répartition des cas selon l'année de réception, présentée dans le tableau 2, met en évidence une forte concentration des déclarations sur la période 2020–2025, aux côtés de quelques observations isolées rattachées à des années antérieures.

TABLE 2 – Répartition des cas selon l'année de réception

Année de réception	Nombre de cas
1900	990
2011	1
2012	1
2015	1
2017	17
2018	7
2019	41
2020	5 935
2021	5 121
2022	5 001
2023	5 820
2024	5 503
2025	773
Non renseignée	9 348
Total	38 559

2.1.3 Description des variables

Parmi les 98 variables disponibles dans la base brute, une grande partie documente des informations secondaires ou redondantes par rapport à l'objectif de ce projet ; informations sur plusieurs produits associés à un même cas, symptômes codés séparément, champs de traitement peu renseignés, etc. Ce projet se concentre sur un sous-ensemble de onze variables, directement liées au profil du patient, aux circonstances de l'exposition et à

l'issue clinique du cas ; les critères ayant guidé ce choix, ainsi que le traitement des variables écartées, sont détaillés dans la section 2.2.1. Le tableau 3 présente ces onze variables.

TABLE 3 – Description des variables retenues pour l'étude

Variable	Description	Type
Age Année	Âge du patient, en années	Numérique
Sexe	Sexe du patient	Catégorielle
Milieu	Milieu de résidence (urbain / rural)	Catégorielle
Région	Région administrative de déclaration du cas	Catégorielle
Circonstance	Contexte général de l'exposition	Catégorielle
Sous circons- tance	Précision de la circonstance d'exposition	Catégorielle
type de produit1	Catégorie générale du produit en cause	Catégorielle
Produit 1	Dénomination précise du produit en cause	Catégorielle
Voie 1	Voie d'exposition au toxique	Catégorielle
Symptomatologie	Présence de signes cliniques rapportés	Catégorielle
Gradation finale	Grade de gravité clinique (variable cible)	Catégorielle

2.1.4 Variable cible : la Gradation finale

La variable *Gradation finale* constitue la variable cible du projet : c'est elle que les modèles développés dans ce travail cherchent à prédire à partir des caractéristiques du cas déclaré. Elle correspond au grade de gravité clinique final attribué au patient à l'issue du suivi de son intoxication, sur une échelle allant de l'absence de symptôme au décès. Le Tableau 4 détaille la signification de chacune des six modalités présentes dans la base.

TABLE 4 – Modalités de la variable cible *Gradation finale*

Grade	Signification
Grade 0	Aucun signe clinique, ou signes non en rapport avec l'intoxication
Grade 1	Signes cliniques spontanément régressifs
Grade 2	Signes cliniques prononcés
Grade 3	Intoxication sévère, avec risque vital
Grade 4	Décès du patient
Grade 5	Cas inclassable, évolution clinique inconnue

Le grade 5 se distingue des autres modalités : il ne traduit pas un niveau de gravité à proprement parler, mais l'impossibilité de statuer sur l'évolution du cas, faute de suivi clinique suffisant. Cette spécificité est prise en compte dans les choix méthodologiques présentés au Chapitre 3.

2.2 Prétraitement des données

Cette section détaille les traitements appliqués à la base brute présentée précédemment, afin d'obtenir un jeu de données fiable et exploitable pour la modélisation. Elle couvre successivement la sélection de la période d'étude et des variables, la gestion des valeurs manquantes, l'harmonisation des variables catégorielles, et enfin l'encodage de la variable cible.

2.2.1 Sélection de la période d'étude et des variables

Sélection de la période

Comme le montre le Tableau 2, la base brute contient un petit nombre d'observations rattachées à des années antérieures à 2020 : 990 cas déclarés avec l'année 1900, manifestement une valeur par défaut ou une erreur de saisie, ainsi que 68 cas répartis entre 2011 et 2019, trop peu nombreux et trop dispersés dans le temps pour être représentatifs. Ces observations ont été écartées, afin de ne conserver que la période 2020–2025, cohérente sur le plan temporel et suffisamment fournie (37 501 observations) pour permettre une modélisation robuste. Le Tableau 5 présente la répartition des cas sur la période finalement retenue.

TABLE 5 – Répartition des cas par année sur la période retenue (2020-2025)

Année	Nombre de cas
2020	5 935
2021	5 121
2022	5 001
2023	5 820
2024	5 503
2025	773
Non renseignée	9 348
Total	37 501

On notera que 9 348 cas de la base ne comportent aucune date de réception renseignée. Ces observations ont néanmoins été conservées dans la base de travail : l'année de réception n'intervenant à aucun moment comme variable explicative du modèle (cf. Tableau 3), son absence ne constitue pas un motif d'exclusion, contrairement aux cas explicitement rattachés à une période hors du champ retenu (1900, et 2011 à 2019).

Sélection des variables

Sur les 98 variables disponibles, seules onze ont été retenues pour cette étude (tableau 3), sur la base de deux critères principaux : leur pertinence directe pour caractériser un cas d'intoxication et prédire sa gravité, et leur disponibilité dès la déclaration initiale du cas. Ce second critère exclut d'emblée toute variable renseignée a posteriori (traitement administré, évolution détaillée), qui ne serait pas exploitable dans une logique de prédiction précoce.

Trois variables supplémentaires : Famille1 (famille toxicologique du produit), délai d'intox (délai entre l'exposition et la prise en charge) et Hospitalisation, répondaient a priori à ces critères, mais présentaient un taux de valeurs manquantes trop élevé pour être exploitées de façon fiable ; elles ont donc été écartées à cette étape. Le reste des 98 variables correspond à des informations redondantes (produits ou symptômes secondaires associés à un même cas) ou à des champs purement administratifs (numéro de dossier, type de déclarant), sans intérêt direct pour la modélisation.

À l'issue de cette double sélection, période d'étude et variables, la base de travail comporte 37 501 observations et 14 variables (Tableau 6), avant tout traitement des valeurs manquantes, détaillé dans la section suivante.

TABLE 6 – Dimensions de la base après sélection de la période et des variables

Élément	Nombre
Cas (observations)	37 501
Variables	14

2.2.2 Gestion des valeurs manquantes

Une fois la période et les variables sélectionnées, la base comporte 37 501 observations et 14 variables. L’examen des valeurs manquantes sur cet ensemble révèle une hétérogénéité importante selon les variables, certaines étant quasiment complètes tandis que d’autres présentent des taux de valeurs manquantes très élevés (Tableau 7).

TABLE 7 – Taux de valeurs manquantes avant traitement

Variable	% de valeurs manquantes
Famille1	81,31
délai d’intox (heure)	60,11
Hospitalisation	50,34
Gradation finale (cible)	17,15
Symptomatologie	10,77
Milieu	9,27
Voie 1	8,58
Age Année	6,29
Sexe	3,40
Produit 1	2,50
Sous circonstance	2,36
Circonstance	1,29
Région	1,19
type de produit1	0,02

Un cas particulier concerne la variable *Région*, qui présentait initialement un taux de valeurs manquantes bien plus élevé (37,63 %) que celui indiqué au Tableau 7. L’examen de la base brute a révélé l’existence d’une seconde colonne, *Région_12*, encodant la même information mais avec un taux de valeurs manquantes nettement plus faible (1,15 %). Cette colonne a donc été utilisée en remplacement de la variable *Région* d’origine, permettant de récupérer une information quasi complète sans perte de qualité.

Un traitement particulier est réservé à la variable *Gradation finale*, qui constitue la

cible de la modélisation menée dans ce projet (voir le tableau 4). Avec un taux de valeurs manquantes de 17,15 %, elle ne peut faire l’objet d’aucune imputation : contrairement à une variable explicative, attribuer arbitrairement un grade de gravité à un cas pour lequel cette information n’a jamais été recueillie reviendrait à fabriquer une donnée sans fondement clinique, avec un risque réel de biaiser l’apprentissage du modèle. C’est pour cette raison que les observations concernées sont supprimées plutôt qu’imputées, comme détaillé dans l’Étape 2 ci-dessous.

Le traitement des valeurs manquantes s’est ensuite déroulé en deux étapes.

Étape 1 : Suppression des variables trop incomplètes. Les trois variables présentant les taux de valeurs manquantes les plus élevés : *Famille1* (81,31 %), *délai d’into*x (60,11 %) et *Hospitalisation* (50,34 %), ont été retirées du jeu de données. À un tel niveau d’incomplétude, toute imputation aurait introduit un biais trop important pour rester acceptable, tandis que la suppression des lignes concernées aurait entraîné une perte de données bien trop conséquente.

Étape 2 : Suppression des observations sans valeur cible. La variable *Gradation finale*, qui constitue la cible de la modélisation, ne peut faire l’objet d’aucune imputation : une valeur manquante sur cette variable signifie qu’aucune information de gravité n’est disponible pour le cas concerné, rendant son exploitation impossible pour un problème d’apprentissage supervisé. Les 6 430 observations concernées (17,15 % de la base) ont donc été supprimées, ramenant la base à 31 071 observations et 11 variables.

Le Tableau 8 résume l’effet de cette étape sur la variable cible.

TABLE 8 – Valeurs manquantes de la variable cible avant et après traitement

Variable	Avant (%)	Après (%)
Gradation finale (cible)	17,15	0,00

À l’issue de ces deux étapes, les taux de valeurs manquantes restants, présentés dans le Tableau 9, sont nettement plus modérés et permettent d’envisager une imputation raisonnable des observations concernées.

TABLE 9 – Taux de valeurs manquantes après suppression des variables et des observations sans cible

Variable	% de valeurs manquantes
Symptomatologie	10,12
Voie 1	9,98
Age Année	5,74
Milieu	3,86
Sexe	2,64
Produit 1	2,00
Sous circonstance	1,48
Région	1,32
Circonstance	1,14
type de produit1	0,02

Les valeurs manquantes restantes ont été traitées différemment selon la nature des variables :

- Pour les **variables catégorielles** (*Symptomatologie, Voie 1, Milieu, Sexe, Produit 1, Sous circonstance, Région, Circonstance, type de produit1*), les valeurs manquantes ont été remplacées par la modalité explicite « *Inconnu* », plutôt que par le mode ou une suppression des lignes. Ce choix permet de conserver l'ensemble des observations tout en traitant l'absence d'information comme une catégorie à part entière, potentiellement porteuse de sens (une variable non renseignée n'étant pas nécessairement due au hasard).
- Pour la variable **numérique** *Age Année*, une vérification préalable a permis d'identifier des valeurs non numériques résiduelles, converties en valeurs manquantes (portant leur nombre de 2359 à 2601), avant qu'une imputation par la **médiane** (17 ans) ne soit appliquée, un choix plus robuste que la moyenne face à la distribution asymétrique de l'âge des patients.

À l'issue de cette étape, la base ne comporte plus aucune valeur manquante sur les 11 variables retenues, comme le confirme le Tableau 10.

TABLE 10 – Taux de valeurs manquantes avant et après imputation

Variable	Avant (%)	Après (%)
Symptomatologie	10,12	0,00
Voie 1	9,98	0,00
Age Année	5,74	0,00
Milieu	3,86	0,00
Sexe	2,64	0,00
Produit 1	2,00	0,00
Sous circonstance	1,48	0,00
Région	1,32	0,00
Circonstance	1,14	0,00
type de produit1	0,02	0,00

2.2.3 Encodage et traitement de la variable cible

La variable *Gradation finale*, comme les autres variables catégorielles, souffrait d'une forte hétérogénéité de saisie : un même grade de gravité pouvait être enregistré sous plusieurs formes textuelles (« Grade 2 : Signes prononcés », « 2 : signes prononcés », « Grade 2 :Signes prononcés »...). Une fonction d'harmonisation dédiée a donc été appliquée, recherchant le chiffre caractéristique de chaque grade (0 à 5) dans le texte pour le ramener à une forme standardisée (« Grade 0 » à « Grade 5 »), les valeurs ne comportant aucun chiffre reconnaissable étant classées « Inconnu ». Le Tableau 11 présente la distribution obtenue à l'issue de cette harmonisation.

TABLE 11 – Distribution de la variable cible après harmonisation, avant épuration

Grade	Nombre de cas
Grade 2	9 932
Grade 5	8 786
Grade 0	7 929
Grade 1	3 567
Grade 3	605
Grade 4	155
Inconnu	97
Total	31 071

Deux modalités ont ensuite été retirées de la variable cible.

La modalité *Inconnu* (97 cas) correspond à des libellés de gravité qui n'ont pu être rattachés à aucun grade reconnaissable ; elle ne porte donc, comme les valeurs manquantes traitées en section 2.2.2, aucune information exploitable pour l'apprentissage et a été supprimée pour les mêmes raisons.

La modalité *Grade 5* (8 786 cas, soit 28,3 % de la base à ce stade) appelle une justification différente. Comme précisé au Tableau 4, ce grade ne correspond pas à un niveau de gravité clinique : il signale un cas dont l'évolution n'a pas pu être suivie jusqu'à son terme, faute d'information de retour suffisante. Il ne s'agit donc pas d'un cinquième degré de sévérité comparable aux grades 0 à 4, mais de l'absence de conclusion clinique sur le cas, une information de nature différente de celle que le modèle cherche à prédire. Conserver cette modalité aurait revenu à demander au modèle d'apprendre à prédire une catégorie qui ne reflète pas une gravité réelle, ce qui n'aurait pas de sens clinique et aurait mécaniquement dégradé la qualité de l'apprentissage sur les grades effectivement informatifs. Les cas de Grade 5 ont donc été retirés du jeu de données, au même titre que les cas de gravité inconnue.

À l'issue de cette épuration, la base de travail comporte 22 188 observations, réparties sur les cinq grades de gravité réels, comme le montre le Tableau 12.

TABLE 12 – Distribution finale de la variable cible *Gradation finale*

Grade	Nombre de cas	%
Grade 2	9 932	44,8
Grade 0	7 929	35,7
Grade 1	3 567	16,1
Grade 3	605	2,7
Grade 4	155	0,7
Total	22 188	100,0

Ce tableau met déjà en évidence le déséquilibre marqué de la variable cible, les grades sévères (3 et 4) représentant à eux deux moins de 3,5 % des cas, contre près de 80 % pour les grades 0 et 2 réunis. Ce constat, approfondi dans l'analyse exploratoire ci-après, justifiera le recours aux techniques de rééquilibrage présentées au Chapitre 3.

2.2.4 Harmonisation des variables catégorielles

Au-delà du traitement des valeurs manquantes, l'examen des modalités brutes des variables catégorielles a révélé une hétérogénéité importante, imputable au mode de saisie de

la base : une même information pouvait être orthographiée de plusieurs façons différentes (majuscules, accents, espaces superflus, abréviations), ou associée à des libellés synonymes (« Non précisé », « NP », « Inconnu », « Inconnue » pour une même absence d'information, par exemple). Cette dispersion, si elle n'était pas corrigée, aurait artificiellement démultiplié le nombre de modalités de chaque variable et nuirait à la qualité de l'encodage réalisé en vue de la modélisation.

Pour y remédier, une fonction d'harmonisation a été définie pour chacune des huit variables catégorielles concernées (*Sexe*, *Milieu*, *Région*, *Circonstance*, *Sous circonstance*, *type de produit1*, *Voie 1*, *Symptomatologie*). Le principe retenu est commun à toutes ces variables : chaque valeur brute est normalisée (minuscules, suppression des espaces superflus), puis recherchée par mots-clés caractéristiques afin d'être rattachée à une catégorie standardisée ; les valeurs ne correspondant à aucun mot-clé reconnu, ou explicitement non renseignées, sont regroupées sous la modalité « *Inconnu* ». Le Tableau 13 résume, pour chaque variable, l'effet de cette harmonisation sur le nombre de modalités.

TABLE 13 – Réduction du nombre de modalités après harmonisation

Variable	Modalités brutes	Modalités après harmonisation
Sexe	10	3
Milieu	8	3
Région	21	12
Circonstance	12	4
Sous circonstance	41	13
type de produit1	55	14
Voie 1	82	7
Symptomatologie	13	3

Deux cas méritent d'être détaillés. La variable *Voie 1* présentait la dispersion la plus marquée : ses 82 valeurs brutes correspondaient souvent à une même voie d'exposition déclinée de multiples façons (« Orale », « orale », « Orale, Autres », « Orale / iv »...), ramenée après harmonisation à sept catégories cliniquement homogènes (Orale, Cutanée, Inhalation, Injection, Rectale, Oculaire, Inconnu), la voie orale restant très largement majoritaire. La variable *Région* a par ailleurs nécessité une attention particulière : au-delà des variantes orthographiques (« Oriental » / « L'oriental », « Laâyoune-Sakia El Hamra » / « Laayoune-Sakia El Hamra »), la colonne *Région_12*, déjà mobilisée pour réduire les valeurs manquantes (voir Section 2.2.1), a servi de base à cette harmonisation, ramenant les 21 libellés bruts aux 12 régions administratives officielles du Maroc.

Cas particulier de la variable “Produit”

La variable *Produit 1*, qui désigne la dénomination précise du produit ou de la substance en cause dans l’intoxication, se distingue radicalement des autres variables catégorielles : il s’agit d’un champ de saisie libre, comptant 5 960 valeurs uniques pour 22 188 observations. Une harmonisation par mots-clés, adaptée aux variables précédentes à faible cardinalité, n’était donc pas envisageable ici. Un pipeline de nettoyage en quatre étapes a été construit spécifiquement pour cette variable.

Standardisation du texte : Une première étape de normalisation systématique a été appliquée à chaque valeur : mise en majuscules, suppression des espaces multiples et des espaces en début/fin de chaîne, puis suppression des accents (par décomposition Unicode). Ce nettoyage, purement syntaxique, a permis de fusionner automatiquement les doublons liés à la casse ou à la ponctuation, faisant passer le nombre de produits uniques de 5 960 à 4 861 (soit une réduction de 18 %). Une vérification a ensuite confirmé qu’aucun doublon de ce type ne subsistait après cette étape.

Détection de doublons par similarité textuelle : Les doublons restants correspondent principalement à des fautes de frappe ou à des variantes d’écriture non couvertes par la standardisation précédente (« DOLIPRANE 1G » / « DOLIPRANE 1 G », « MONOXYDE DE CARBON » / « MONOXYDE DE CARBONE »). Pour les identifier, une mesure de similarité textuelle (ratio de *SequenceMatcher*) a été calculée entre chaque paire de produits parmi les 847 produits apparaissant au moins trois fois dans la base, les produits plus rares étant, de toute façon, destinés à la catégorie « AUTRE » lors du regroupement final. Avec un seuil de similarité fixé à 0,85, 113 paires suspectes ont été détectées et soumises à une relecture manuelle.

Construction d’un dictionnaire de synonymes : Les 113 paires suspectes ont fait l’objet d’une vérification manuelle afin d’écarter les rapprochements erronés (deux produits réellement distincts mais orthographiquement proches) et de ne retenir que les véritables doublons. Un dictionnaire de synonymes a ainsi été constitué, associant chaque variante confirmée à sa forme de référence (par exemple « PILLULE CONTRACEPTIVE » → « PILULE CONTRACEPTIVE », « ACIDE CHLORYDRIQUE » → « ACIDE CHLORHYDRIQUE »). Son application a permis de réduire encore le nombre de produits uniques de 4 861 à 4 786.

Regroupement des produits rares (*Produit_Regroupe*) : Malgré ce travail de fusion, le nombre de produits distincts restait bien trop élevé pour être exploité directement comme variable catégorielle dans un modèle de classification. Une nouvelle variable, *Produit_Regroupe*, a donc été créée en conservant, en tant que catégorie à part entière,

uniquement les produits apparaissant au moins 30 fois dans la base, soit 92 produits, et en regroupant l'ensemble des autres sous la modalité « AUTRE ». Cette variable compte ainsi 93 catégories, dont 43,0 % des observations relèvent de la modalité « AUTRE ». Ce seuil constitue un compromis entre la nécessité de limiter la dimensionnalité de la variable une fois encodée et celle de préserver un niveau d'information suffisant sur les produits les plus fréquemment en cause dans les intoxications sévères.

Le Tableau 14 illustre la répartition des observations entre les 92 produits conservés individuellement et la catégorie résiduelle « AUTRE ».

TABLE 14 – Répartition des cas entre produits nommés et catégorie « AUTRE »

Catégorie	Nombre de cas	%
Produits nommés (92 catégories)	12 647	57,0
AUTRE	9 541	43,0
Total	22 188	100,0

Exclusion de la variable *Symptomatologie* Bien que complète et disponible dès la déclaration à l'issue du prétraitement, la variable *Symptomatologie* a été écartée du jeu de données final. Cette variable indique la présence ou l'absence de signes cliniques chez le patient, une information qui entre directement dans la définition même du grade de gravité le plus bénin (Grade 0 : « Aucun signe clinique, ou signes non en rapport avec l'intoxication », voir Tableau 4). Sa conservation aurait fait peser un risque de fuite de données (*data leakage*) sur l'ensemble de la démarche : l'information qu'elle porte est trop directement corrélée à la variable cible elle-même pour constituer une variable explicative légitime, quelle que soit la méthode de modélisation retenue par la suite. Elle a donc été retirée à ce stade, au même titre que les variables exclues en section 2.2.1.

À l'issue de l'ensemble des traitements décrits dans ce chapitre : sélection de la période et des variables, gestion des valeurs manquantes, encodage de la variable cible, harmonisation des variables catégorielles et exclusion de *Symptomatologie*, la base de travail finale comporte 22 188 observations et les dix variables présentées dans le Tableau 15.

TABLE 15 – Variables retenues à l’issue du prétraitement

Variable	Rôle
Age Année	Explicative
Sexe	Explicative
Milieu	Explicative
Région	Explicative
Circonstance	Explicative
Sous circonstance	Explicative
type de produit1	Explicative
Produit 1 / Produit_Regroupe	Explicative
Voie 1	Explicative
Gradation finale	Cible

2.3 Analyse exploratoire des données

2.3.1 Distribution de la variable cible

La Figure 2.1 présente la distribution des cas selon les cinq grades de la variable *Gradation finale*, sur l’ensemble des 22 188 observations retenues à l’issue du prétraitement.




FIGURE 2.1 – Distribution des cas selon le grade de gravité

Cette distribution confirme le déséquilibre déjà relevé au Tableau 12 : les grades 0 et 2 concentrent à eux seuls près de 80 % des cas (respectivement 7 929 et 9 932 observations), tandis que le Grade 1 en rassemble 3 567. Les intoxications sévères (Grade 3, 605 cas) et les décès (Grade 4, 155 cas) ne représentent ensemble que 2,7 % et 0,7 % des observations, soit à peine 760 cas sur 22 188. Ce déséquilibre marqué, typique des problèmes de classification en santé où les événements les plus graves sont aussi les plus rares, constitue l'un des principaux défis méthodologiques du projet : il oriente directement les choix effectués au Chapitre 3 en matière de rééquilibrage des classes (SMOTE, SMOTENC) et de métriques d'évaluation privilégiant la détection des cas sévères (rappel de la classe sévère, F2-score).

2.3.2 Analyse univariée des variables explicatives

L'âge des patients présente une distribution fortement asymétrique (Figure 2.2), avec un âge médian de 17 ans, un âge moyen de 18,7 ans (écart-type de 16,6 ans) et une forte concentration des cas chez les jeunes enfants (premier quartile à 4 ans), reflet du poids des intoxications accidentelles domestiques dans la petite enfance.




FIGURE 2.2 – Distribution de l'âge des patients

Cette bimodalité apparente ; un pic chez les tout-petits, puis une seconde concentration à l'âge adulte jeune, se confirme sur le découpage en tranches d'âge (Figure 2.3).




FIGURE 2.3 – Répartition des cas par tranche d'âge

Pour les autres variables explicatives, le Tableau 16 résume, pour chacune, la modalité la plus fréquente et son poids relatif.

TABLE 16 – Modalité dominante par variable explicative catégorielle

Variable	Modalité dominante	%
Sexe	Féminin	49,6
Milieu	Urbain	70,1
Région	Casablanca-Settat	18,2
Circonstance	Accidentelle	73,1
Sous circonstance	Accident classique	57,0
type de produit1	Médicament	37,5
Voie 1	Orale	75,9
Symptomatologie	Oui	61,9

Ce tableau met en évidence le profil type d'un cas déclaré au CAPM : une intoxication accidentelle, par voie orale, survenue en milieu urbain, le plus souvent liée à un médicament ou à un accident domestique classique.

2.3.3 Relations bivariées avec la gravité




FIGURE 2.4 – Gravité des intoxications selon le sexe




FIGURE 2.5 – Gravité des intoxications selon la tranche d'âge




FIGURE 2.6 – Gravité des intoxications selon le milieu




FIGURE 2.7 – Gravité des intoxications selon la région




FIGURE 2.8 – Âge des patients en fonction du grade de sévérité

Profil sociodémographique et gravité L'âge se distingue comme l'une des variables les plus nettement associées à la gravité : l'âge moyen croît de façon quasi monotone avec le grade, de 13,1 ans pour le Grade 0 à 25,6 ans pour le Grade 4 (Tableau 17), confirmant visuellement ce que suggère le boxplot de la Figure 2.8.

TABLE 17 – Âge moyen des patients par grade de gravité

Grade	Âge moyen (années)
Grade 0	13,1
Grade 1	21,2
Grade 2	22,0
Grade 3	22,7
Grade 4	25,6

Produits en cause et gravité Les tableaux croisés des Figures 2.9 et 2.10, exprimés en pourcentage par ligne, permettent de comparer directement la répartition des grades de gravité selon la circonstance et selon le type de produit en cause.




FIGURE 2.9 – Répartition du grade de gravité (%) selon la circonstance

La circonstance « Effet indésirable » se distingue par la proportion la plus élevée de cas de Grade 2 (56,7 %), suivie de « Inconnu » (50,5 %) et « Volontaire » (47,0 %), tandis que les cas accidentels se répartissent de façon plus équilibrée entre Grade 0 (38,1 %) et Grade 2 (43,6 %). Les circonstances volontaire et inconnue concentrent également, en proportion, le plus de cas sévères (Grade 3 : 5,0 % et 3,5 % respectivement, contre 2,0 % pour les cas accidentels).




FIGURE 2.10 – Répartition du grade de gravité (%) selon le type de produit

Le type de produit en cause fait apparaître des profils de gravité très contrastés. Certains produits sont associés à une gravité quasi systématiquement élevée : les métaux lourds sont classés à 100,0 % en Grade 2, et les intoxications au gaz atteignent 78,9 % de Grade 2. À l'inverse, les cosmétiques (66,2 %) et les médicaments (52,3 %) présentent majoritairement des cas de Grade 0, traduisant des expositions généralement bénignes. Les plantes et les morsures de serpent se distinguent par une part plus élevée de cas sévères (Grade 3 : 9,2 % et 6,5 % respectivement), tout comme les cas de produit inconnu (Grade 3 : 6,7 %, Grade 4 : 4,6 %), cette dernière catégorie regroupant sans doute des cas dont la gravité clinique a compliqué l'identification précise du toxique en cause.

2.3.4 Tests statistiques d'association

Afin de confirmer statistiquement les associations suggérées par l'analyse graphique précédente, un test du Chi-2 d'indépendance a été appliqué entre chaque variable catégorielle explicative et la variable cible. Le Tableau 18 présente les résultats obtenus.

TABLE 18 – Test du Chi-2 — Association avec la Gradation finale

Variable	p-value	Conclusion
Sexe	< 0,001	Significatif
Milieu	< 0,001	Significatif
Région	< 0,001	Significatif
Circonstance	< 0,001	Significatif
Sous circonstance	< 0,001	Significatif
type de produit1	< 0,001	Significatif
Voie 1	< 0,001	Significatif
Tranche_age	< 0,001	Significatif

L'ensemble des variables catégorielles testées présente une association statistiquement significative avec la gravité ($p < 0,001$). Le test du Chi-2 indique toutefois seulement la présence d'une association, sans en mesurer l'intensité ; une variable peut être significative sur un aussi grand nombre d'observations (22 188) tout en n'ayant qu'un pouvoir explicatif limité.

Pour la variable numérique *Age Année*, un test de Kruskal-Wallis a été utilisé afin de comparer la distribution de l'âge entre les cinq grades de gravité, sans hypothèse de normalité. Le test confirme une différence hautement significative entre les groupes (statistique = 2 160,52 ; $p < 0,001$), cohérente avec la progression de l'âge moyen déjà observée au Tableau 17.

Afin de départager les variables selon la force réelle de leur association avec la gravité, et non uniquement leur significativité, le V de Cramér a été calculé pour chacune des variables catégorielles (Tableau 19).

TABLE 19 – V de Cramér — Force de l'association avec la Gradation finale

Variable	V de Cramér
type de produit1	0,226
Tranche_age	0,183
Sous circonstance	0,150
Région	0,145
Voie 1	0,132
Circonstance	0,084
Milieu	0,081
Sexe	0,067

Parmi les variables conservées pour la modélisation, *type de produit1* ($V = 0,226$) et *Tranche_age* ($V = 0,183$) présentent les associations les plus marquées avec la gravité, suivies de *Sous circonstance* et *Région* ($V \approx 0,15$). *Sexe* et *Milieu* affichent, à l'inverse, les associations les plus faibles ($V < 0,10$), bien que statistiquement significatives.

2.4 Méthodologie adoptée

La démarche méthodologique suivie pour la construction des modèles de classification, détaillée au Chapitre 3, s'articule autour d'un pipeline commun : prétraitement des données (Chapitre 2), séparation du jeu de données en ensembles d'entraînement et de test, correction du déséquilibre des classes, entraînement et optimisation des modèles, puis évaluation selon des métriques adaptées au contexte clinique du projet.

Avant tout entraînement, la base de 22 188 observations a été séparée en un ensemble d'entraînement (80 %, soit 17 750 cas) et un ensemble de test (20 %, soit 4 438 cas), ce dernier n'intervenant à aucun moment dans la construction ou le réglage des modèles et servant uniquement à l'évaluation finale de leurs performances. Cette séparation a été réalisée de façon stratifiée selon la variable cible, c'est-à-dire en conservant, dans chacun des deux ensembles, une proportion de chaque grade de gravité identique à celle observée dans la base complète. Ce choix est particulièrement important compte tenu du déséquilibre marqué de la variable cible mis en évidence en section 2.3.1 : sans stratification, un tirage aléatoire simple risquerait de produire un ensemble de test contenant trop peu de cas de Grade 3 ou Grade 4 pour permettre une évaluation fiable des performances du modèle sur ces classes critiques. Le Tableau 20 détaille cette répartition.

TABLE 20 – Répartition des observations entre entraînement et test

Grade	Entraînement (80 %)	Test (20 %)	Total
Grade 0	6 343	1 586	7 929
Grade 1	2 854	713	3 567
Grade 2	7 945	1 987	9 932
Grade 3	484	121	605
Grade 4	124	31	155
Total	17 750	4 438	22 188

L'évaluation des modèles obtenus repose sur trois métriques principales, choisies pour leur adéquation au contexte de classes déséquilibrées et à la nature clinique du problème : le F1-macro, qui accorde un poids égal à chaque grade quelle que soit sa fréquence, évitant

qu'une bonne exactitude apparente masque une mauvaise détection des classes rares ; le Quadratic Weighted Kappa, qui tient compte du caractère ordonné des grades de gravité en pénalisant davantage une confusion entre grades éloignés qu'entre grades adjacents ; et le rappel de la classe sévère, retenu comme critère clinique prioritaire puisqu'un cas grave non détecté constitue, dans ce contexte, une erreur bien plus coûteuse qu'une fausse alerte. Ces métriques, ainsi que les raisons détaillées de leur choix, sont présentées en section 3.6.

Modélisation

Ce chapitre présente la démarche de modélisation mise en œuvre pour prédire la gravité clinique d’une intoxication à partir des variables retenues au chapitre précédent. Il détaille successivement les modèles de classification testés, les deux stratégies de construction envisagées selon le traitement de la variable *Produit*, la méthode retenue pour corriger le déséquilibre des classes, la fusion des grades de sévérité les plus rares, la démarche d’optimisation des hyperparamètres, et enfin les métriques mobilisées pour évaluer les modèles obtenus.

3.1 Modèles de prédiction utilisés

Trois familles de modèles de classification supervisée ont été testées et comparées dans le cadre de ce projet, choisies pour leur complémentarité : un modèle linéaire simple et interprétable servant de référence, et deux modèles d’ensemble à base d’arbres de décision, réputés performants sur des données tabulaires hétérogènes.

3.1.1 Régression logistique

La régression logistique constitue le modèle de référence (*baseline*) de ce travail. Il s’agit d’un modèle linéaire qui estime, pour chaque classe de la variable cible, la probabilité d’appartenance à partir d’une combinaison linéaire des variables explicatives, transformée par une fonction logistique (softmax dans le cas multiclasse). Sa simplicité et son interprétabilité directe (chaque coefficient traduit l’effet marginal d’une variable sur la probabilité d’une classe) en font un point de comparaison indispensable avant de recourir à des modèles plus complexes.

3.1.2 Random Forest

Le Random Forest (forêt aléatoire) est un modèle d’ensemble reposant sur l’agrégation d’un grand nombre d’arbres de décision, chacun entraîné sur un sous-échantillon aléatoire des observations (*bagging*) et un sous-ensemble aléatoire des variables à chaque nœud de décision. Cette double randomisation réduit la variance du modèle et limite le risque de surapprentissage propre à un arbre de décision unique. La prédiction finale résulte d’un vote majoritaire (classification) entre les arbres de la forêt. Ce modèle présente l’avantage de capter naturellement des interactions non linéaires entre variables, sans nécessiter d’hypothèse a priori sur la forme de la relation entre les prédicteurs et la cible, un atout important compte tenu du caractère multifactoriel de la gravité d’une intoxication, mis en évidence au chapitre précédent.

3.1.3 XGBoost

XGBoost (*Extreme Gradient Boosting*) est également un modèle d'ensemble à base d'arbres, mais reposant sur un principe différent : le *boosting*. Plutôt que d'entraîner les arbres indépendamment les uns des autres, chaque nouvel arbre est construit de façon à corriger les erreurs commises par l'ensemble des arbres précédents, par optimisation successive d'une fonction de perte. XGBoost intègre par ailleurs plusieurs mécanismes de régularisation (pénalisation de la complexité des arbres) destinés à limiter le surapprentissage. Ce modèle a été retenu comme second candidat de comparaison, en raison de ses performances généralement élevées sur des problèmes de classification tabulaire, mais aussi pour ses résultats parfois moins stables observés dans ce projet (cf. Chapitre 4).

3.2 Stratégies de construction des modèles

Deux stratégies de construction du jeu de variables explicatives ont été comparées, selon la façon dont la variable *Produit* est prise en compte dans la modélisation.

3.2.1 Modèles sans regroupement de la variable *Produit*

Une première approche a consisté à exclure la variable *Produit 1* des variables explicatives, en ne conservant que sa version agrégée, *type de produit1*, qui regroupe les produits en un nombre restreint de catégories générales (Médicament, Aliment, Gaz, etc.). Cette approche, plus simple, évite l'explosion du nombre de colonnes générée par l'encodage direct d'une variable comportant plusieurs milliers de modalités distinctes, mais renonce également à toute l'information plus fine que porte le nom exact du produit en cause.

3.2.2 Modèles avec regroupement de la variable *Produit* (*Produit_Regroupe*)

Une seconde approche, retenue pour la version finale du système, a consisté à construire une nouvelle variable, *Produit_Regroupe*, à partir de la variable *Produit 1* nettoyée et harmonisée (cf. section 2.3.2). Seuls les produits apparaissant au moins 30 fois dans la base ont été conservés sous leur propre modalité ; l'ensemble des produits plus rares a été regroupé sous une modalité générique « AUTRE ». Ce seuil a permis de ramener une variable initialement composée de plusieurs milliers de valeurs distinctes à un nombre de modalités directement exploitable par un encodage *one-hot*, tout en conservant, pour les produits les plus fréquents, un niveau de détail plus fin que la seule catégorie générale.




FIGURE 3.1 – Répartition des modalités de la variable *Produit_Regroupe*

Cette seconde stratégie s’est révélée plus performante lors des comparaisons empiriques présentées au Chapitre 4, et a par conséquent été retenue pour la construction du modèle final.

3.3 Traitement du déséquilibre des classes

L’analyse exploratoire menée au Chapitre 2 a mis en évidence un déséquilibre marqué de la variable cible, les grades de gravité sévère (Grade 3 et Grade 4) étant fortement sous-représentés par rapport aux autres classes. Ce déséquilibre constitue un défi méthodologique central : un modèle entraîné sans précaution particulière tend à privilégier la prédiction des classes majoritaires, au détriment de la détection des cas les plus critiques, précisément ceux qu’un système d’aide à la décision se doit de repérer en priorité.

3.3.1 Principe de la technique SMOTE

SMOTE (*Synthetic Minority Over-sampling Technique*) est une méthode de rééquilibrage des classes par sur-échantillonnage synthétique. Plutôt que de dupliquer simplement

des observations existantes de la classe minoritaire, SMOTE génère de nouvelles observations synthétiques par interpolation linéaire entre une observation de la classe minoritaire et l'un de ses plus proches voisins appartenant à la même classe. Pour deux observations x_a et x_b de la classe minoritaire, une nouvelle observation synthétique x_{new} est ainsi générée selon :

$$x_{\text{new}} = x_a + \lambda \times (x_b - x_a), \quad \lambda \in [0, 1] \quad (3.1)$$

où λ est tiré aléatoirement dans l'intervalle $[0, 1]$. Cette approche permet d'enrichir artificiellement les classes minoritaires sans se contenter de répéter des observations identiques, réduisant ainsi le risque de surapprentissage sur un nombre restreint de cas dupliqués.

3.3.2 Limites de SMOTE appliqué après encodage One-Hot

L'application directe de SMOTE nécessite néanmoins une vigilance particulière lorsque les variables explicatives sont, pour l'essentiel, catégorielles. Dans la mise en œuvre initiale de ce projet, l'encodage *one-hot* des variables catégorielles a été réalisé *avant* l'application de SMOTE, chaque modalité étant alors représentée par une colonne binaire (0 ou 1). Or, le mécanisme d'interpolation linéaire propre à SMOTE ne préserve pas la nature binaire de ces colonnes : pour deux observations x_a et x_b dont une colonne binaire vaut respectivement 1 et 0, l'interpolation peut produire une valeur intermédiaire (par exemple 0,3 ou 0,7) dépourvue de toute signification catégorielle. Les observations synthétiques ainsi générées peuvent alors combiner des modalités de variables incompatibles entre elles, sans correspondre à aucun profil de patient plausible.

Ce constat, qui n'affecte pas la validité mathématique de l'algorithme mais sa pertinence pour des données majoritairement catégorielles, a conduit à reconsidérer la méthode de rééquilibrage retenue pour la version finale du modèle.

3.3.3 Correction méthodologique : SMOTENC pour variables catégorielles

Afin de remédier à cette limite, la variante SMOTENC (*SMOTE for Nominal and Continuous features*) a été retenue pour la version finale du système. Contrairement à SMOTE appliqué après encodage, SMOTENC intervient directement sur les données brutes, *avant* l'encodage *one-hot*, en distinguant explicitement les variables catégorielles des variables numériques continues (dans ce projet, seul l'âge du patient). Pour les variables numériques, l'interpolation linéaire classique de SMOTE est conservée ; pour les variables catégorielles en revanche, la valeur retenue pour chaque nouvelle observation synthétique est choisie parmi les modalités effectivement présentes chez les plus proches

voisins, plutôt qu'interpolée. Cette approche garantit que chaque observation synthétique demeure composée exclusivement de modalités réellement observées dans les données, préservant ainsi la cohérence catégorielle des cas générés.




FIGURE 3.2 – Comparaison schématique du mécanisme d'interpolation de SMOTE et de SMOTENC sur une variable catégorielle

Cette correction méthodologique s'est traduite, lors des comparaisons empiriques détaillées au Chapitre 4, par une amélioration sensible du rappel sur la classe sévère par rapport à l'approche SMOTE initiale, confirmant la pertinence de cette adaptation au contexte du projet.

3.3.4 Intégration dans un pipeline de validation croisée

Un point de vigilance méthodologique essentiel a guidé l'intégration du rééquilibrage des classes dans la démarche d'évaluation : le rééquilibrage, qu'il s'agisse de SMOTE ou de SMOTENC, ne doit en aucun cas être appliqué à l'ensemble du jeu de données avant la séparation entraînement/test, ni avant chacun des plis de la validation croisée. Une telle pratique introduirait une fuite de données (*data leakage*) : des observations synthétiques générées à partir d'informations issues du jeu de test se retrouveraient alors dans le jeu d'entraînement, conduisant à une évaluation artificiellement optimiste des performances du modèle.

Pour éviter cet écueil, SMOTENC a été intégré au sein d'un *pipeline* scikit-learn (via la bibliothèque *imbalanced-learn*), englobant successivement l'étape de rééquilibrage, l'encodage *one-hot* des variables catégorielles, puis l'entraînement du modèle. Ce pipeline est ensuite soumis dans son intégralité à la procédure de validation croisée : à chaque pli,

le rééquilibrage n'est appliqué qu'aux données d'entraînement du pli considéré, jamais aux données de validation, garantissant ainsi une évaluation non biaisée des performances du modèle.




FIGURE 3.3 – Schéma du pipeline SMOTENC intégré à la validation croisée

3.4 Fusion des grades de sévérité

Comme évoqué au Chapitre 2, la variable cible comporte initialement cinq grades de gravité exploitables (Grade 0 à Grade 4), le Grade 5 étant écarté en raison de son caractère non informatif sur le plan clinique (cas inclassable, évolution inconnue). Or, l'analyse des effectifs disponibles pour chacun de ces cinq grades révèle un déséquilibre particulièrement marqué pour les grades les plus sévères : le Grade 3 et le Grade 4 ne représentent, à eux deux, qu'une faible fraction de l'ensemble des observations, le Grade 4 (décès) étant, à lui seul, la modalité la plus rare de l'ensemble de la variable cible.

Ce déséquilibre extrême rend la distinction fine entre Grade 3 et Grade 4 statistiquement peu robuste : le nombre d'observations disponibles pour le Grade 4 s'avère insuffisant pour permettre un apprentissage fiable des frontières de décision propres à cette classe, y compris après rééquilibrage synthétique. Il a par conséquent été décidé de fusionner les Grades 3 et 4 en une classe unique, dénommée « *Sévère (3-4)* », regroupant l'ensemble des intoxications sévères avec risque vital ou ayant entraîné le décès du patient. Cette fusion répond à un double objectif : d'une part, renforcer la fiabilité statistique de l'apprentissage sur cette classe critique en augmentant son effectif ; d'autre part, recentrer l'enjeu

clinique du modèle sur une question opérationnellement plus pertinente pour le CAPM : distinguer les cas à risque vital des cas de gravité moindre, plutôt que sur une distinction plus fine, mais peu fiable, entre survie sévère et décès.

TABLE 21 – Effectifs des grades sévères avant et après fusion

Modalité	Nombre de cas
Grade 3 (avant fusion)	605
Grade 4 (avant fusion)	155
Sévère (3-4), après fusion	760

Le problème de classification traité dans la suite de ce rapport porte ainsi sur quatre classes : Grade 0, Grade 1, Grade 2, et Sévère (3-4).

3.5 Optimisation des hyperparamètres

Les performances des modèles à base d’arbres (Random Forest et XGBoost) dépendent sensiblement du réglage de leurs hyperparamètres. Une recherche par validation croisée a été menée pour chacun de ces modèles, à l’aide de la procédure `RandomizedSearchCV` de scikit-learn. Contrairement à une recherche exhaustive sur grille (*Grid Search*), qui testerait systématiquement toutes les combinaisons possibles d’hyperparamètres au prix d’un temps de calcul prohibitif, `RandomizedSearchCV` tire aléatoirement un nombre fixé de combinaisons au sein de l’espace de recherche défini, offrant un compromis raisonnable entre qualité d’exploration et temps de calcul.

Deux recherches d’hyperparamètres distinctes ont été menées pour le Random Forest, correspondant aux deux pipelines de rééquilibrage comparés au Chapitre 4 : une première portant sur le pipeline associé à SMOTE classique, une seconde sur le pipeline SMOTENC finalement retenu pour la version finale du système. Les deux recherches partagent une partie de leur espace d’exploration (nombre d’arbres, profondeur, tailles minimales de scission et de feuille), mais diffèrent sur un hyperparamètre spécifique à chacune : le pipeline SMOTE classique explore le choix du nombre de variables considérées à chaque scission (`max_features`), tandis que le pipeline SMOTENC explore la stratégie de pondération des classes (`class_weight`). Le Tableau 22 détaille ces deux espaces de recherche.

TABLE 22 – Espace de recherche des hyperparamètres pour le Random Forest, selon le pipeline

Hyperparamètre	Pipeline SMOTE classique	Pipeline SMOTENC
Nombre d'arbres (<code>n_estimators</code>)	100, 200, 300, 500	100, 200, 300
Profondeur maximale (<code>max_depth</code>)	aucune limite, 10, 15, 20, 30	10, 20, 30, aucune limite
Taille min. de scission (<code>min_samples_split</code>)	2, 5, 10	2, 5, 10
Taille min. d'une feuille (<code>min_samples_leaf</code>)	1, 2, 4	1, 2, 4
Variables par scission (<code>max_features</code>)	sqrt, log2	—
Pondération des classes (<code>class_weight</code>)	—	balanced, balanced_subsample

Une recherche similaire a été menée pour le modèle XGBoost, sur l'espace de recherche présenté au Tableau 23.

TABLE 23 – Espace de recherche des hyperparamètres pour XGBoost

Hyperparamètre	Valeurs testées
Nombre d'arbres (<code>n_estimators</code>)	100, 200, 300
Profondeur maximale (<code>max_depth</code>)	4, 6, 8, 10
Taux d'apprentissage (<code>learning_rate</code>)	0,01 ; 0,05 ; 0,1 ; 0,2
Sous-échantillonnage des observations (<code>subsample</code>)	0,7 ; 0,8 ; 1,0
Sous-échantillonnage des variables (<code>colsample_bytree</code>)	0,7 ; 0,8 ; 1,0

La recherche a été effectuée sur 20 combinaisons tirées aléatoirement, évaluées par validation croisée à 3 plis, en optimisant le F1-macro, métrique détaillée en section 3.6.3, plutôt que l'exactitude globale, afin de ne pas favoriser une configuration privilégiant artificiellement les classes majoritaires.

3.6 Métriques d'évaluation des performances

Le choix des métriques d'évaluation constitue un enjeu à part entière dans un contexte de classes déséquilibrées. Cette section présente les différentes métriques mobilisées pour évaluer et comparer les modèles construits, ainsi que la justification du critère retenu comme prioritaire.

3.6.1 Matrice de confusion (VP, FP, VN, FN)

La matrice de confusion constitue l'outil de base de l'évaluation d'un modèle de classification : elle croise, pour chaque classe, les prédictions du modèle avec les valeurs réellement

observées. Pour une classe donnée, on distingue ainsi les Vrais Positifs (VP, cas correctement prédits comme appartenant à la classe), les Faux Positifs (FP, cas prédits à tort comme appartenant à la classe), les Vrais Négatifs (VN, cas correctement prédits comme n'appartenant pas à la classe) et les Faux Négatifs (FN, cas appartenant réellement à la classe mais non détectés par le modèle). Dans le contexte de ce projet, les Faux Négatifs sur la classe Sévère revêtent une importance clinique particulière, puisqu'ils correspondent à des cas graves non détectés par le système.

3.6.2 Précision, rappel et F1-score

À partir des quantités précédentes, deux métriques complémentaires peuvent être calculées pour chaque classe :

$$\text{Précision} = \frac{VP}{VP + FP}, \quad \text{Rappel} = \frac{VP}{VP + FN} \quad (3.2)$$

La précision mesure la proportion de prédictions positives effectivement correctes, tandis que le rappel (*recall*) mesure la proportion de cas réellement positifs correctement détectés par le modèle. Ces deux métriques évoluent généralement en sens opposé : un modèle plus prudent dans ses prédictions positives améliore sa précision au prix d'un rappel plus faible, et inversement. Le F1-score synthétise ce compromis par leur moyenne harmonique :

$$F1 = 2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}} \quad (3.3)$$

3.6.3 F1-macro

Le F1-macro consiste à calculer le F1-score indépendamment pour chaque classe, puis à en faire la moyenne arithmétique non pondérée :

$$\text{F1-macro} = \frac{1}{K} \sum_{k=1}^K F1_k \quad (3.4)$$

où K désigne le nombre de classes. Contrairement à l'exactitude globale (*accuracy*), qui peut afficher une valeur trompeusement élevée en cas de fort déséquilibre des classes (un modèle prédisant systématiquement la classe majoritaire pouvant obtenir une exactitude apparente satisfaisante sans jamais détecter les classes minoritaires), le F1-macro accorde un poids égal à chaque classe, quelle que soit sa fréquence. Cette propriété en fait une métrique nettement plus adaptée à l'évaluation de modèles sur des données déséquilibrées, et elle a par conséquent été retenue comme métrique principale d'optimisation dans ce projet.

3.6.4 Quadratic Weighted Kappa (QWK)

La variable cible de ce projet présentant un caractère *ordonné* (les grades de gravité constituent une échelle croissante), une métrique tenant compte de cet ordre a également été mobilisée : le Quadratic Weighted Kappa. Cette métrique, dérivée du coefficient Kappa de Cohen, pénalise les erreurs de classification proportionnellement au carré de la distance entre le grade prédit et le grade réel : une confusion entre deux grades adjacents (par exemple Grade 2 prédit à la place de Grade 3) est ainsi bien moins pénalisée qu'une confusion entre deux grades éloignés (par exemple Grade 0 prédit à la place de la classe Sévère). Le QWK varie de -1 (désaccord total) à 1 (accord parfait), la valeur 0 correspondant à un accord équivalent au hasard. Cette métrique a permis d'évaluer les modèles non pas uniquement sur leur capacité à prédire exactement le bon grade, mais sur leur capacité à s'en approcher, ce qui revêt un intérêt clinique particulier compte tenu de la nature graduée de la gravité d'une intoxication.

Formellement, pour un problème à K classes ordonnées, le QWK se calcule à partir de trois matrices $K \times K$: la matrice des poids quadratiques w , la matrice des effectifs observés O (la matrice de confusion), et la matrice des effectifs attendus sous indépendance E (produit des distributions marginales des classes réelles et prédites, normalisé pour avoir la même somme totale que O). Le poids attribué à chaque paire de classes (i, j) croît avec le carré de leur écart :

$$w_{i,j} = \frac{(i - j)^2}{(K - 1)^2} \quad (3.5)$$

Le QWK est alors défini par :

$$\kappa = 1 - \frac{\sum_{i,j} w_{i,j} O_{i,j}}{\sum_{i,j} w_{i,j} E_{i,j}} \quad (3.6)$$

Le numérateur mesure ainsi l'écart pondéré réellement observé entre prédictions et valeurs réelles, tandis que le dénominateur représente l'écart pondéré attendu si les prédictions étaient indépendantes des valeurs réelles (accord dû au hasard). Plus κ se rapproche de 1 , meilleur est l'accord entre le modèle et les valeurs réelles ; à l'inverse, plus il se rapproche de 0 , plus cet accord se confond avec un résultat obtenu par hasard.

Cette métrique a permis d'évaluer les modèles non pas uniquement sur leur capacité à prédire exactement le bon grade, mais sur leur capacité à s'en approcher, ce qui revêt un intérêt clinique particulier compte tenu de la nature graduée de la gravité d'une intoxication.

3.6.5 Choix du rappel (recall) comme critère clinique prioritaire

Au-delà des métriques globales précédentes, le rappel calculé spécifiquement sur la classe Sévère a été retenu comme critère d'évaluation prioritaire pour la sélection du modèle final. Ce choix découle directement de l'enjeu clinique du projet : dans un contexte d'aide à la décision médicale, un Faux Négatif sur la classe Sévère, c'est-à-dire un cas gravement intoxiqué non détecté par le système, constitue une erreur nettement plus coûteuse qu'un Faux Positif, qui se traduirait tout au plus par une vigilance accrue, injustifiée a posteriori, de la part du praticien. Ce choix méthodologique a directement guidé la comparaison des modèles présentée au Chapitre 4, ainsi que l'optimisation du seuil de décision par le F2-score, qui pondère explicitement le rappel deux fois plus que la précision.

Résultats et interprétation

Ce chapitre présente les résultats obtenus au cours des différentes étapes de construction du modèle, depuis les premiers essais jusqu’à la version finale retenue. Il détaille successivement les résultats des modèles testés à chaque étape méthodologique du Chapitre 3, les résultats obtenus sur le problème final à quatre classes, la sélection du modèle retenu, son interprétation par la méthode SHAP, et enfin une discussion critique des résultats et de leurs limites.

4.1 Résultats des modèles testés

4.1.1 Résultats sans regroupement de la variable Produit

Une première série de modèles a été entraînée en excluant toute information fine sur le produit en cause, seule la catégorie générale (`type de produit1`) étant retenue comme variable explicative, sur le problème à cinq classes (Grade 0 à Grade 4). Il s’agit à ce stade de modèles avec hyperparamètres par défaut (non encore optimisés) : un Random Forest (`n_estimators=200`) et un XGBoost pondéré par les poids d’échantillon (`class_weight='balanced'` via `compute_sample_weight`). Le Tableau 24 présente les résultats obtenus.

TABLE 24 – Performances des modèles initiaux, sans regroupement de la variable Produit (5 classes)

Modèle	F1-macro	QWK	Recall Grade 4
Random Forest (par défaut)	0,40	0,420	0,06
XGBoost (pondéré)	0,39	0,393	0,16

Ces premiers résultats, obtenus avant toute optimisation d’hyperparamètres, montrent des performances globales proches entre les deux modèles, avec un léger avantage au Random Forest sur le F1-macro et le QWK. XGBoost, grâce à la pondération des classes, obtient en revanche un meilleur rappel sur le Grade 4, la classe la plus rare (16 % contre 6 % pour le Random Forest), illustrant l’intérêt d’une stratégie de rééquilibrage dès cette étape exploratoire.

4.1.2 Résultats avec regroupement de la variable Produit

Une seconde série de modèles a intégré la variable `Produit_Regroupe`, ainsi que la fusion des Grades 3 et 4 en une classe unique « Sévère (3-4) » (cf. section 3.4), portant le problème à quatre classes. Le Tableau 25 compare les performances d’une régression logistique (retenue comme référence de base, sans optimisation d’hyperparamètres) à celles

du Random Forest et de XGBoost, tous deux optimisés par `RandomizedSearchCV` et associés à un rééquilibrage par SMOTE classique (appliqué après encodage *one-hot*).

TABLE 25 – Performances des modèles avec `Produit_Regroupe` et fusion des grades sévères (SMOTE classique)

Modèle	F1-macro	QWK	Recall Sévère
Régression logistique (baseline)	0,448	0,462	4,0 %
Random Forest (optimisé)	0,534	0,478	27,0 %
XGBoost (optimisé)	0,530	0,489	17,8 %

L'intégration de la variable `Produit_Regroupe` et la fusion des grades sévères améliorent sensiblement les performances globales par rapport à l'étape précédente. La régression logistique, retenue comme référence de base, atteint un F1-macro et un QWK globalement comparables à ceux des modèles plus complexes, mais échoue presque totalement à détecter la classe Sévère (recall de seulement 4,0 %) : sa frontière de décision linéaire ne parvient pas à isoler cette classe minoritaire des trois autres, malgré le rééquilibrage par SMOTE. Cette limite illustre concrètement l'intérêt des modèles à base d'arbres pour ce problème, capables de capturer des interactions non linéaires entre variables plus favorables à la détection des cas sévères. Parmi ceux-ci, le Random Forest se distingue par un rappel nettement supérieur sur la classe Sévère (27,0 % contre 17,8 % pour XGBoost), pour un F1-macro quasiment identique entre les deux modèles.

4.1.3 Résultats après optimisation des hyperparamètres

L'optimisation des hyperparamètres par `RandomizedSearchCV`, décrite en section 3.5, a été appliquée à deux pipelines distincts, dont les espaces de recherche et les meilleures configurations diffèrent :

- pour le **Random Forest associé à SMOTE classique** (Tableau 25), la meilleure configuration retenue est `n_estimators=500`, `min_samples_split=2`, `min_samples_leaf=2`, `max_features='sqrt'`, `max_depth` non contraint (score F1-macro en validation croisée : 0,517) ;
- pour le **Random Forest associé à SMOTENC** (modèle finalement retenu, cf. section 4.3), la meilleure configuration converge vers `n_estimators=200`, `min_samples_split=5`, `min_samples_leaf=1`, une profondeur maximale de 20, et une stratégie de pondération `balanced_subsample` (score F1-macro en validation croisée : 0,493).

Ces deux configurations, bien que différentes, partagent une profondeur raisonnablement contrainte et un nombre d'arbres de l'ordre de la centaine à quelques centaines, cohérent avec la taille du jeu de données disponible.

4.2 Résultats sur le problème à 4 classes (après fusion des grades sévères)

4.2.1 Comparaison Random Forest vs XGBoost

Au-delà des métriques globales présentées au Tableau 25, la lecture détaillée des rapports de classification révèle un compromis précision/rappel différent entre les deux modèles sur la classe Sévère : le Random Forest atteint une précision de 26 % pour un rappel de 27,0 %, tandis que XGBoost atteint une précision supérieure de 37 % mais pour un rappel plus faible de 17,8 %. Autrement dit, le Random Forest se montre moins conservateur dans sa détection des cas sévères, il en signale proportionnellement davantage, au prix d'un nombre plus élevé de fausses alertes, tandis que XGBoost privilégie une détection plus sûre mais plus restrictive. Ce compromis favorise le Random Forest au regard du critère clinique prioritaire retenu en section 4.2.5 (maximiser le rappel sur la classe Sévère).

4.2.2 Random Forest avec SMOTENC (variables catégorielles brutes)

Conformément à la correction méthodologique présentée en section 3.3.3, le modèle Random Forest a été ré-entraîné avec SMOTENC plutôt que SMOTE classique, cette fois appliqué directement sur les variables catégorielles brutes, avant tout encodage. Le Tableau 26 compare les performances obtenues avec SMOTE classique et SMOTENC, pour un modèle Random Forest par ailleurs comparable.

TABLE 26 – Comparaison SMOTE classique et SMOTENC (Random Forest, 4 classes)

Méthode de rééquilibrage	F1-macro	QWK	Recall Sévère
SMOTE classique	0,534	0,478	27,0 %
SMOTENC	0,513	0,467	32,9 %

Ce résultat illustre concrètement l'intérêt de la correction méthodologique introduite par SMOTENC : bien que les métriques globales (F1-macro, QWK) soient très légèrement inférieures à celles obtenues avec SMOTE classique, le rappel sur la classe Sévère, retenu comme critère clinique prioritaire (cf. section 3.6.5), progresse de près de six points, passant de 27,0 % à 32,9 %. Cette amélioration confirme que le respect de la nature catégorielle des variables lors du rééquilibrage permet au modèle d'apprendre des frontières de décision plus fidèles à la réalité clinique pour la classe la plus critique, au prix d'un léger recul sur les métriques agrégées.

4.2.3 Validation par cross-validation (stabilité des résultats)

Afin de s'assurer que les différences observées entre les modèles ne relèvent pas d'un artefact lié au hasard du découpage entraînement/test, une validation croisée à 5 plis stratifiés a été réalisée sur les deux modèles associés à SMOTE classique. Le Random Forest obtient un F1-macro moyen de 0,515 (écart-type 0,012) sur les 5 plis, avec un rappel moyen sur la classe Sévère de 20,2 % (écart-type 0,028). Le modèle XGBoost, évalué dans les mêmes conditions, obtient un F1-macro moyen très proche de 0,518 (écart-type 0,007), mais un rappel moyen sur la classe Sévère sensiblement plus faible, de 15,0 % (écart-type 0,015). Ces résultats confirment la stabilité globale des deux modèles indépendamment du découpage retenu, tout en renforçant l'avantage du Random Forest sur la détection de la classe Sévère, cohérent avec les résultats obtenus sur l'ensemble de test unique.

4.2.4 Matrices de confusion et courbes ROC / precision-recall

La Figure 4.1 présente la matrice de confusion du modèle Random Forest avec SMO-TENC, le modèle finalement retenu, sur le jeu de test, en valeurs brutes et en pourcentages normalisés par classe réelle.




FIGURE 4.1 – Matrice de confusion du modèle Random Forest + SMOTENC




FIGURE 4.2 – Matrice de confusion normalisée (pourcentage par classe réelle)

La lecture de la matrice de confusion confirme que les erreurs de classification se concentrent majoritairement entre classes adjacentes (par exemple entre Grade 1 et Grade 2), plutôt qu'entre classes éloignées, ce qui est cohérent avec la valeur du Quadratic Weighted Kappa obtenue.

La Figure 4.3 présente les courbes ROC one-vs-rest pour chacune des quatre classes, avec l'aire sous la courbe (AUC) associée.




FIGURE 4.3 – Courbes ROC multiclasse (one-vs-rest) : Random Forest + SMOTENC

4.2.5 Choix du seuil de décision optimal (F2-score) pour la classe Sévère

Plutôt que de retenir le seuil de décision par défaut (0,5), une analyse du compromis précision/rappel a été menée sur la probabilité prédite d'appartenance à la classe Sévère, en identifiant le seuil maximisant le F2-score, métrique qui pondère le rappel deux fois plus fortement que la précision, cohérente avec le critère clinique prioritaire retenu en section 3.6.5. Le Tableau 27 présente les résultats obtenus pour différents seuils testés.

TABLE 27 – Recall, précision et F2-score selon le seuil de décision (classe Sévère, SMO-TENC)

Seuil	Recall	Précision	F2-score
0,50	21,7 %	20,5 %	0,215
0,40	27,6 %	18,3 %	0,251
0,35	32,2 %	17,5 %	0,276
0,30	36,8 %	14,3 %	0,280
0,25	46,1 %	13,2 %	0,307
0,20	50,7 %	10,8 %	0,291
0,15	62,5 %	8,7 %	0,280
0,10	74,3 %	6,3 %	0,234




FIGURE 4.4 – Compromis précision/rappel selon le seuil de décision, classe Sévère

Le seuil de 0,25 maximise le F2-score et a été retenu comme seuil de décision opérationnel du système : à ce seuil, 46,1 % des cas réellement sévères sont détectés par le modèle, contre seulement 21,7 % au seuil par défaut de 0,5. Ce choix est directement intégré à l'application développée au Chapitre 5, où toute probabilité de classe Sévère supérieure à ce seuil déclenche un message d'alerte spécifique, y compris lorsque la classe prédite par le modèle n'est pas Sévère.

4.3 Sélection du modèle final

Au terme de l'ensemble des comparaisons menées dans ce chapitre, le modèle retenu comme version finale du système est un Random Forest entraîné avec SMOTENC, intégrant la variable `Produit_Regroupe`, sur le problème à quatre classes (Grade 0, Grade 1, Grade 2, Sévère). Ce choix repose sur trois éléments convergents : un rappel sur la classe Sévère nettement supérieur à celui obtenu avec SMOTE classique ou avec XGBoost (32,9 % contre respectivement 27,0 % et 17,8 %) ; une stabilité confirmée par validation croisée sur les pipelines comparables ; et un comportement de prédiction mesuré, sans tendance excessive à la sur-prédiction de la classe sévère observée chez XGBoost. Le seuil de décision optimisé à 0,25 complète ce choix pour maximiser l'utilité clinique du système.

4.4 Interprétabilité du modèle (SHAP)

4.4.1 Méthodologie SHAP

Afin de rendre les prédictions du modèle interprétables, condition indispensable pour un système d'aide à la décision destiné à un usage clinique, la méthode SHAP (*SHapley Additive exPlanations*) a été mobilisée. Fondée sur la théorie des jeux coopératifs, cette méthode attribue à chaque variable une contribution (valeur de Shapley) à l'écart entre la prédiction du modèle pour une observation donnée et la prédiction moyenne du modèle sur l'ensemble des données. L'implémentation `TreeExplainer`, spécifiquement optimisée pour les modèles à base d'arbres, a été utilisée pour exploiter efficacement la structure du Random Forest retenu.

4.4.2 Importance des variables pour la classe Sévère

La Figure 4.5 présente l'importance moyenne de chaque variable dans les prédictions du modèle vers la classe Sévère, mesurée par la moyenne des valeurs absolues de Shapley sur un échantillon du jeu de test.




FIGURE 4.5 – Importance des variables (SHAP) pour la prédiction de la classe Sévère

La Figure 4.6 complète cette lecture globale par une représentation détaillée, indiquant non seulement l'importance de chaque variable mais également le sens de son effet sur la prédiction.




FIGURE 4.6 – Impact détaillé des variables (SHAP) sur la prédiction de la classe Sévère

4.4.3 Comparaison de l'interprétabilité entre Random Forest et XGBoost

L'analyse SHAP a également été menée sur le modèle XGBoost, à titre de comparaison. Si les variables les plus influentes se recoupent globalement entre les deux modèles (âge, type de produit, circonstance de l'exposition), une différence notable a été observée sur le poids accordé aux variables régionales : le modèle XGBoost tend à accorder un poids sensiblement plus élevé à la variable Région que le Random Forest, sans que cette différence trouve une justification clinique évidente. Cette observation renforce la préférence

accordée au Random Forest, dont la hiérarchie des variables déterminantes apparaît plus directement interprétable et cohérente avec les connaissances toxicologiques de référence.

4.4.4 Discussion clinique des variables déterminantes

Les variables identifiées comme les plus déterminantes par l'analyse SHAP : l'âge du patient, le type de produit en cause, et la circonstance de l'exposition (en particulier le caractère volontaire de l'intoxication), correspondent aux facteurs de gravité classiquement documentés en toxicologie clinique. Cette cohérence entre les résultats de la modélisation et les connaissances établies dans la littérature constitue un élément de validité supplémentaire du modèle retenu, au-delà des seules métriques statistiques de performance.

4.5 Discussion des résultats et limites

Plusieurs limites doivent être soulignées quant à l'interprétation des résultats présentés dans ce chapitre.

Premièrement, malgré la fusion des Grades 3 et 4, la classe Sévère demeure la classe la moins représentée du jeu de données, ce qui explique la précision relativement faible obtenue sur cette classe (de l'ordre de 13 % au seuil retenu) : le modèle, en cherchant à maximiser la détection des cas sévères, génère nécessairement un nombre important de fausses alertes, compromis assumé au regard de l'enjeu clinique prioritaire de ce projet.

Deuxièmement, un biais géographique potentiel ne peut être exclu : les variations observées entre régions pourraient refléter des différences réelles d'exposition aux risques toxicologiques, mais aussi des différences dans l'accès aux structures de déclaration ou dans la qualité de la documentation des cas selon les régions, sans qu'il soit possible, avec les données disponibles, de distinguer ces deux effets.

Enfin, la catégorie « AUTRE » de la variable **Produit_Regroupe**, qui concentre 43,0 % des observations du jeu de données, constitue une limite intrinsèque à l'approche retenue : les cas impliquant un produit rare ou mal identifié sont traités de façon indifférenciée par le modèle, ce qui peut atténuer la capacité du système à distinguer des profils de gravité propres à certains produits peu fréquents mais potentiellement dangereux.

Conception du système d'aide à la décision

Ce chapitre décrit la conception du système d'aide à la décision développé pour rendre le modèle retenu directement utilisable en pratique clinique. Il présente d'abord l'architecture générale du système, avant de détailler la conception de l'interface développée avec Streamlit et les principales fonctionnalités qu'elle intègre. Il se conclut par quelques pistes d'amélioration envisageables pour la suite du projet.

5.1 Architecture générale du système

Le système d'aide à la décision développé dans ce projet repose sur une architecture en deux temps, découplant volontairement l'entraînement du modèle de son utilisation en production. D'une part, l'ensemble du travail décrit aux Chapitres 2 et 3, prétraitement des données, nettoyage de la variable *Produit*, entraînement du pipeline SMO-TENC + Random Forest, optimisation du seuil de décision, a été réalisé une fois pour toutes dans l'environnement de développement (notebook), puis figé sous forme d'artefacts sauvegardés. D'autre part, une application Streamlit autonome charge ces artefacts au démarrage et les réutilise pour produire des prédictions en temps réel, sans jamais ré-exécuter la phase d'entraînement.

Six artefacts sont ainsi exportés à l'issue de l'entraînement et rechargés par l'application (Tableau 28) : le pipeline de modélisation complet (encodage inclus), la liste des colonnes attendues en entrée, la liste des produits jugés suffisamment fréquents pour être conservés individuellement (cf. section 2.2.4), le dictionnaire des valeurs possibles pour chaque variable catégorielle (utilisé pour peupler les menus déroulants de l'interface), le dictionnaire de synonymes de produits, et le seuil de décision optimal retenu pour la classe Sévère.

TABLE 28 – Artefacts du modèle final chargés par l'application

Artefact	Rôle
<code>pipeline_randomforest_smotenc.pkl</code>	Pipeline complet (encodage + modèle)
<code>colonnes_features.pkl</code>	Ordre des variables attendu en entrée
<code>liste_produits_frequents.pkl</code>	Produits conservés individuellement
<code>valeurs_categorielles.pkl</code>	Modalités possibles par variable
<code>synonymes_produits.pkl</code>	Dictionnaire de synonymes de produits
<code>seuil_optimal_severe.pkl</code>	Seuil de décision pour la classe Sévère

Un point de vigilance méthodologique a guidé la conception de cette architecture : le prétraitement appliqué à un nouveau cas saisi dans l'application doit reproduire exactement celui appliqué lors de l'entraînement, sous peine de présenter au modèle des données

dans un format qu'il n'a jamais appris à reconnaître. C'est le cas en particulier pour la variable *Produit* : la fonction de nettoyage du texte saisi (mise en majuscules, suppression des accents et des espaces superflus) ainsi que le dictionnaire de synonymes sont directement repris du pipeline de prétraitement présenté en section 2.2.4, avant d'appliquer le même seuil de fréquence pour rattacher le produit saisi à une catégorie connue ou, à défaut, à la modalité « AUTRE ».

Cette architecture, résumée à la Figure 5.1, garantit ainsi la cohérence entre les données sur lesquelles le modèle a été entraîné et celles qu'il reçoit en production, tout en permettant des temps de réponse quasi instantanés, aucun calcul lourd n'étant nécessaire au moment de la prédiction, le pipeline étant chargé une seule fois en mémoire (`@st.cache_resource`) puis réutilisé pour chaque nouvelle saisie.




FIGURE 5.1 – Architecture générale du système d'aide à la décision

5.2 Conception de l'interface (Streamlit)

L'interface utilisateur du système a été développée avec Streamlit, un framework Python permettant de construire des applications web interactives directement à partir de scripts Python, sans nécessiter de développement front-end séparé (HTML/CSS/JavaScript). Ce choix technique a permis de connecter directement le pipeline de modélisation entraîné en Python à une interface utilisable sans compétence en développement web, tout en offrant une flexibilité suffisante pour personnaliser l'apparence de l'application (section 5.2.2).

5.2.1 Chargement des artefacts du modèle final

Le chargement des six artefacts présentés en section 5.1 (Tableau 28) est encapsulé dans une fonction dédiée, décorée par `@st.cache_resource`. Ce décorateur, propre à

Streamlit, garantit que les artefacts ne sont chargés depuis le disque qu’une seule fois, au premier démarrage de l’application, puis conservés en mémoire et réutilisés pour toutes les prédictions suivantes, sans cette précaution, le pipeline complet (encodage et forêt de plusieurs centaines d’arbres) serait rechargé à chaque interaction de l’utilisateur avec l’interface, ce qui dégraderait fortement les temps de réponse. Cette mise en cache est ce qui permet à l’application d’afficher un résultat de prédiction de façon quasi instantanée après la saisie d’un cas.

5.2.2 Ergonomie et charte visuelle

L’interface a été conçue autour d’un thème sombre de type *dashboard*, organisé en trois onglets : Accueil, Prédiction et Historique, permettant de séparer clairement la présentation du système, son utilisation opérationnelle, et le suivi des prédictions effectuées au cours d’une session (Figure 5.2).




FIGURE 5.2 – Onglet d’accueil de l’application

L’onglet d’accueil présente le système au moyen d’indicateurs clés (nombre de cas analysés, période couverte, nombre de classes de gravité, modèle retenu), ainsi qu’un rappel de l’échelle de gravité utilisée par le modèle et de la conduite à tenir clinique associée à chaque classe (Tableau 29), afin que l’utilisateur puisse interpréter une prédiction sans avoir à se référer à un document externe.

TABLE 29 – Échelle de gravité et conduite à tenir associée, affichées dans l’application

Classe	Description	Conduite à tenir
Grade 0	Aucun signe clinique	Surveillance à domicile
Grade 1	Signes légers spontanément régressifs	Consultation médicale
Grade 2	Signes prononcés nécessitant un traitement	Hospitalisation
Sévère (3-4)	Intoxication sévère avec risque vital, ou décès	Réanimation urgente / prise en charge immédiate

Un code couleur cohérent avec la gravité clinique a été appliqué à l’ensemble de l’interface : vert pour le Grade 0, bleu pour le Grade 1, orange pour le Grade 2, rouge pour la classe Sévère, afin que l’utilisateur puisse identifier au premier coup d’œil le niveau d’urgence associé à une prédiction, sans avoir à lire le texte en détail.

Les Figures 5.3 et 5.4 illustrent le fonctionnement de l’interface sur un cas fictif : un patient de 15 ans, de sexe masculin, résidant en milieu urbain dans la région de Rabat-Salé-Kénitra, dans un contexte d’exposition volontaire à visée suicidaire, par voie orale, à une drogue.

Centre Anti Poison et de Pharmacovigilance du Maroc

Système d'aide à la décision - Prédiction de la gravité des intoxications

Prédiction

INFORMATIONS DU CAS

Age (années): 15

Sexe: Masculin

Milieu: Urbain

Région: Rabat-Salé-Kénitra

Circonstance: Volontaire

Sous circonstance: Suicidaire

Type de produit: Drogue

Nom du produit (tel que rapporté): [redacted]

Voie d'exposition: Orale

Tranche d'âge: 15-30 ans

Prédire la gravité

© CAPM - Centre Anti Poison et de Pharmacovigilance du Maroc

FIGURE 5.3 – Formulaire de saisie d’un cas dans l’onglet Prédiction

Pour ce cas, le modèle prédit la classe *Sévère (3-4)* avec une probabilité de 38,5 %, et l'application affiche en conséquence un message d'alerte recommandant une prise en charge urgente (Figure 5.4). Le graphique en barres accompagnant la prédiction permet en outre à l'utilisateur de visualiser la probabilité attribuée par le modèle à chacune des quatre classes, ici, les classes Grade 1 (35,9 %) et Sévère (38,5 %) apparaissent proches l'une de l'autre, illustrant un cas où le modèle hésite entre deux issues possibles plutôt que de trancher avec certitude, une information utile au praticien au-delà de la seule classe retenue.



FIGURE 5.4 – Résultat de la prédiction pour le cas saisi

Cette répartition partagée entre plusieurs classes, plutôt qu'une probabilité massivement concentrée sur une seule d'entre elles, n'est pas un défaut du modèle mais le reflet d'une incertitude clinique réelle : les seules variables disponibles à la déclaration ne permettent pas toujours de distinguer avec certitude l'issue d'un cas, en particulier pour des combinaisons de circonstances peu spécifiques (ici, une exposition volontaire à un produit de catégorie « Drogue », sans substance ni dose précisées). Ce comportement illustre concrètement l'intérêt du seuil de décision abaissé (0,25) retenu en section 4.2.5 : plutôt que d'attendre une probabilité dominante avant de déclencher une alerte, le système reste sensible à un signal de gravité même partiel, conformément à l'objectif clinique prioritaire de ne pas manquer de cas sévères.

5.3 Fonctionnalités et intégration du modèle

Au-delà de la saisie d'un cas et de l'affichage d'une prédiction, déjà illustrés en section 5.2.2, l'application intègre deux fonctionnalités complémentaires méritant d'être détaillées : la gestion des produits non catalogués, et le suivi de l'historique des prédictions au cours d'une session.

Le champ de saisie du nom de produit étant un champ de texte libre (voir section 5.1), il est impossible de garantir que l'utilisateur saisira systématiquement une dénomination correspondant exactement à l'un des 92 produits conservés individuellement lors du pré-traitement (section 2.2.4). La fonction `regrouper_produit()` applique donc, à chaque saisie, la même chaîne de traitement que celle utilisée à l'entraînement : nettoyage du texte (majuscules, suppression des accents et espaces superflus), puis recherche dans le dictionnaire de synonymes constitué au Chapitre 2. Si le produit ainsi normalisé figure parmi les produits fréquents, il est utilisé tel quel ; sinon, il est automatiquement rattaché à la modalité « AUTRE », garantissant que l'application puisse traiter n'importe quelle saisie sans jamais échouer, même pour un produit totalement absent de la base d'entraînement.

Enfin, l'application conserve, au fil d'une session d'utilisation, un historique des cas saisis et des prédictions correspondantes (`st.session_state.historique`), consultable dans un onglet dédié. Cette fonctionnalité, propre à la session en cours et réinitialisée à chaque redémarrage de l'application, permet au praticien de revenir sur les cas précédemment évalués sans avoir à ressaisir leurs informations, et offre une option pour effacer cet historique à tout moment.

5.4 Perspectives d'amélioration

Plusieurs axes d'amélioration se dégagent des limites identifiées au fil de ce travail, tant sur le plan des données que sur celui du système développé.

Sur le plan des données, trois variables potentiellement informatives : *Famille1*, *délai d'intox* et *Hospitalisation*, ont dû être écartées dès le prétraitement (section 2.2.1) en raison d'un taux de valeurs manquantes trop élevé pour être exploitées de façon fiable. Un effort de complétude de la saisie sur ces variables, au niveau du CAPM, permettrait d'enrichir significativement le modèle : le délai de prise en charge, en particulier, est un déterminant clinique reconnu de la gravité d'une intoxication, dont l'absence constitue une limite importante du système actuel.

Sur le plan de la performance, le rappel du modèle sur la classe Sévère, bien qu'amélioré par l'optimisation du seuil de décision (de 21,7 % à 46,1 %), reste modéré : plus d'un cas sévère sur deux échappe encore à la détection. Cette limite découle directement de la rareté extrême de cette classe dans les données disponibles (760 cas sur 22 188). À mesure que le CAPM continuera à collecter des déclarations, un réentraînement périodique du modèle sur une base élargie permettrait de renforcer progressivement la fiabilité statistique de l'apprentissage sur cette classe critique, sans attendre une refonte complète du système.

Sur le plan fonctionnel, l'application actuelle constitue une preuve de concept fonctionnelle, désormais accessible en ligne via un simple lien, mais reste, à ce stade, un outil de démonstration plutôt qu'un système déployé en routine clinique. Cette accessibilité facilite les retours d'usage et les démonstrations auprès de l'encadrement, mais plusieurs évolutions resteraient nécessaires pour une adoption opérationnelle par le CAPM : la mise en place d'un mécanisme d'authentification et de traçabilité des utilisateurs, la persistance de l'historique des prédictions au-delà d'une session unique (actuellement perdu à chaque redémarrage de l'application), ainsi qu'un retour d'information structuré permettant de comparer, a posteriori, la gravité prédite à la gravité réellement observée pour un cas donné, une boucle de rétroaction qui pourrait, à terme, alimenter les futurs réentraînements du modèle.

Enfin, l'intégration de l'analyse SHAP (Chapitre 4) directement dans l'interface, sous une forme simplifiée et destinée au praticien plutôt qu'au data scientist, permettrait d'expliquer à l'utilisateur, cas par cas, les facteurs ayant le plus influencé une prédiction donnée, renforçant ainsi la confiance et la transparence du système, deux conditions généralement jugées essentielles à l'adoption clinique d'un outil d'aide à la décision fondé sur le Machine Learning.

Conclusion Générale

Les intoxications constituent, au Maroc comme ailleurs, un enjeu de santé publique dont l'évaluation rapide de la gravité conditionne directement la qualité de la prise en charge clinique. Ce projet de fin d'année, réalisé au sein du Centre Anti Poison et de Pharmacovigilance du Maroc, s'est donné pour objectif de construire un système d'aide à la décision capable de prédire cette gravité à partir des seules caractéristiques disponibles dès la déclaration d'un cas.

La démarche suivie a d'abord nécessité un travail conséquent de fiabilisation des données : sur une base brute de 38 559 déclarations et 98 variables, marquée par une hétérogénéité de saisie importante, un prétraitement rigoureux (sélection de la période et des variables, traitement des valeurs manquantes, harmonisation des modalités catégorielles, nettoyage approfondi de la variable Produit) a permis d'aboutir à une base consolidée de 22 188 observations, exploitable de façon fiable pour la modélisation. L'analyse exploratoire menée sur cette base a mis en évidence un déséquilibre marqué de la variable cible ainsi que des associations significatives entre la gravité et plusieurs caractéristiques du cas déclaré : l'âge du patient, le type de produit en cause et la circonstance d'exposition en particulier, orientant directement les choix méthodologiques de la suite du projet.

Trois modèles de classification ont été construits et comparés : régression logistique, Random Forest et XGBoost, le déséquilibre marqué de la classe des intoxications sévères ayant nécessité un traitement méthodologique spécifique (SMOTENC) ainsi qu'une fusion des grades de sévérité les plus rares. Le modèle finalement retenu, un Random Forest couplé à SMOTENC, s'est distingué par ses performances et son interprétabilité, atteignant un rappel de 46,1 % sur la classe sévère après optimisation du seuil de décision, contre 21,7 % au seuil par défaut, une amélioration obtenue au prix d'une précision plus modeste sur cette classe (13,2 % au seuil retenu), compromis assumé au regard de l'enjeu clinique prioritaire du projet : ne pas manquer un cas grave, quitte à générer davantage de fausses alertes. L'analyse SHAP menée sur ce modèle a permis d'identifier l'âge du patient, le type de produit en cause et la circonstance de l'exposition, en particulier son caractère volontaire, comme les facteurs les plus déterminants de la prédiction, une hiérarchie cohérente avec les connaissances établies en toxicologie clinique et venant renforcer la validité du modèle au-delà des seules métriques de performance.

Ce travail a enfin été concrétisé par le développement d'une application interactive, construite avec Streamlit, intégrant le modèle retenu dans un outil directement utilisable par le personnel du CAPM : à partir des caractéristiques d'un cas nouvellement déclaré, l'application fournit une estimation immédiate de sa gravité probable, accompagnée d'une recommandation de conduite à tenir clinique.

Ce projet comporte néanmoins des limites, discutées plus en détail au Chapitre 4 et en section 5.4 : la rareté persistante des cas les plus sévères dans les données disponibles limite le rappel atteignable par le modèle, et l'absence de certaines variables potentiellement

déterminantes (délai de prise en charge, notamment) constitue une piste d'amélioration identifiée pour la suite. Le système développé doit ainsi être compris comme un outil d'aide à la décision venant compléter le jugement clinique du praticien, et non s'y substituer.

Au-delà de son résultat opérationnel, ce projet illustre la valeur prédictive que peut receler une base de données de toxicovigilance constituée sur plusieurs années, dès lors qu'elle est mobilisée avec la rigueur méthodologique qu'exigent des données réelles, hétérogènes et déséquilibrées. Il ouvre ainsi la voie à une exploitation plus systématique des données du CAPM au service de la décision clinique, dans la continuité de sa mission de toxicovigilance.

Bibliographie

- [1] Centre Anti Poison et de Pharmacovigilance du Maroc (CAPM). *Site officiel*. Disponible sur : <https://www.capm-sante.ma/>
- [2] World Health Organization. (1999). *Guidelines for Poison Control*. Disponible sur : <https://www.who.int/publications/i/item/9241544872>
- [3] Rhalem, N., et al. (2015). Toxic deaths : Data from the Poison Control Centre of Morocco (CAPM). *Journal of Forensic and Legal Medicine*, 32, 1-5. Disponible sur : https://www.researchgate.net/publication/275714391_Toxic_deaths_Data_from_the_Poison_Control_Centre_of_Morocco_CAPM
- [4] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE : Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321-357. Disponible sur : <https://arxiv.org/abs/1106.1813>
- [5] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32. Disponible sur : <https://doi.org/10.1023/A:1010933404324>
- [6] Chen, T., & Guestrin, C. (2016). XGBoost : A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. Disponible sur : <https://arxiv.org/abs/1603.02754>
- [7] Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 4765-4774. Disponible sur : <https://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions>
- [8] Cohen, J. (1968). Weighted Kappa : Nominal Scale Agreement with Provision for Scaled Disagreement or Partial Credit. *Psychological Bulletin*, 70(4), 213-220.

Extraits de code

Fonction de nettoyage et de regroupement de la variable *Produit* (cf. section 2.2.4) :

```
def nettoyer_produit(val):  
    val = str(val).strip().upper()  
    val = re.sub(r'\s+', ' ', val)  
    val = retirer_accents(val)  
    return val  
  
def regrouper_produit(val):  
    val = nettoyer_produit(val)  
    val = synonymes.get(val, val)  
    if val in produits_frequents:  
        return val  
    return "AUTRE"
```

Règle de décision fondée sur le seuil optimal (F2-score) pour la classe Sévère (cf. section 4.2.5) :

```
if proba_severe >= seuil_optimal_severe:  
    prediction = "Sévère (3-4)"  
else:  
    prediction = classes[probabilites.argmax()]
```

Dictionnaire des variables

TABLE 30 – Dictionnaire des variables retenues pour la modélisation

Variable	Type	Modalités
Age Année	Numérique	0 à 96 ans (médiane 17 ans)
Sexe	Catégorielle	Féminin, Masculin, Inconnu
Milieu	Catégorielle	Urbain, Rural, Inconnu
Région	Catégorielle	12 régions administratives du Maroc
Circonstance	Catégorielle	Accidentelle, Volontaire, Effet indésirable, Inconnu
Sous circons- tance	Catégorielle	13 catégories (Accident classique, Sui- cidaire, Alimentaire, etc.)
type de pro- duit1	Catégorielle	14 catégories (Médicament, Aliment, Gaz, etc.)
Produit_Regroupé	Catégorielle	93 catégories (92 produits fréquents + AUTRE)
Voie 1	Catégorielle	Orale, Cutanée, Inhalation, Injection, Rectale, Oculaire, Inconnu
Tranche_age	Catégorielle	0-5 ans, 6-15 ans, 16-30 ans, 31-60 ans, Plus de 60 ans
Gradation fi- nale (cible)	Catégorielle	Grade 0, Grade 1, Grade 2, Sévère (3- 4)